

UNIVERSIDADE FEDERAL DO MARANHÃO
CENTRO DE CIÊNCIAS EXATAS E TECNOLÓGICAS
DEPARTAMENTO DE INFORMÁTICA
CURSO DE CIÊNCIA DA COMPUTAÇÃO

PROJETO DE MONOGRAFIA

Análise e Classificação de Termografias Dinâmicas das Mamas Utilizando a Variação de Temperatura e Máquinas de Vetor de Suporte

São Luís

2016

Caio Nogueira Silva Belfort

Aluno do Curso de Ciência da Computação

Prof. Dr. Aristófares Côrrea Silva

Orientador

Prof. Msc. Carlos Eduardo Portela Serra de Castro

Coordenador do Curso de Ciência da Computação

Resumo

A termografia das mamas é um exame de imagem que utiliza a radiação infravermelha naturalmente emitida pelo corpo da paciente para detecção de anomalias. Possui a capacidade de detectar o câncer de mama mais precocemente que a mamografia, sem causar nenhum efeito colateral ou incômodo físico na paciente. O processamento de imagens médicas é uma área que vem ganhando destaque recentemente, pois metodologias de diagnóstico automático podem auxiliar médicos especialistas na detecção de doenças de forma precoce, aumentando as chances de cura. Este trabalho apresenta uma metodologia de processamento e análise de termografias dinâmicas da mama, como forma de auxiliar médicos especialistas no diagnóstico de doenças relacionadas ao tecido mamário. O registro de imagens é utilizado para efetuar a correção do erro de postura entre os diversos tempos de uma termografia dinâmica. Valores estatísticos são utilizados para medir a variação de temperatura entre os pixels, formando novas imagens a partir da termografia original. Em seguida a extração de características de textura é efetuada em cada imagem estatística, formando um conjunto de valores conhecido como vetor de características. O vetor de característica é reduzido através de técnicas de redução de características para posteriormente servir de entrada para uma máquina de vetor de suporte que irá efetuar a classificação em exame saudável ou exame com algum tipo de anomalia. A metodologia apresenta 82,5% de acurácia, 84,1 % de sensibilidade e 81,0% de especificidade.

Palavras chave: Câncer, Mama, Termografia, Aprendizado de Máquina

Lista de ilustrações

Figura 1 – Termografia mamária.	10
Figura 2 – Registro de imagens é a tarefa de achar uma transformação espacial de uma imagem em outra.	11
Figura 3 – Fluxograma do processo de registro de imagens.	12
Figura 4 – Campo de deslocamento da imagem móvel para a imagem fixa.	13
Figura 5 – Posições de grade da imagem fixa mapeadas para posições fora da grade na imagem móvel.	14
Figura 6 – Amostras geradas utilizando um distribuição normal multivariada.	19
Figura 7 – Amostras reduzidas para o espaço bidimensional utilizando os dois principais componentes.	19
Figura 8 – Distância intra-classe.	20
Figura 9 – Distância inter-classes.	20
Figura 10 – Amostras geradas de distribuições normais multivariadas.	21
Figura 11 – Resultado da aplicação do LDA para reduzir as amostras da Figura 10.	22
Figura 12 – Construção de hiperplanos.	23
Figura 13 – Vetores de suporte.	24
Figura 14 – Conjunto de indivíduos não separáveis linearmente.	25
Figura 15 – Fluxograma da metodologia.	26
Figura 16 – Monitoramento da temperatura média para começar a aquisição sequencial.	26
Figura 17 – Termogramas de tempos distintos. Tons mais claros denotam uma maior diferença entre as regiões.	27
Figura 18 – Extração da região das mamas através do software ImageJ.	28
Figura 19 – Temperatura Inicial. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante, onde a região demarcada informa a localização.	30
Figura 20 – Ganho de temperatura total. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante. A região mais avermelhada em (b) coincide com a região em que o tumor aparece.	30
Figura 21 – Ganho de temperatura média entre os tempos da TID. Em (a) vemos um exame de paciente saudável, enquanto em (b) temos uma paciente com lesão na mama.	31
Figura 22 – Desvio padrão do ganho de temperatura entre os tempos da TID. Em (a) vemos um exame de paciente saudável, enquanto em (b) temos uma paciente com lesão na mama, onde a região demarcada informa a região do tumor.	31

Sumário

1	INTRODUÇÃO	7
2	OBJETIVOS	9
2.1	Objetivos Gerais	9
2.2	Objetivos Específicos	9
3	FUNDAMENTAÇÃO TEÓRICA	10
3.1	A Termografia	10
3.1.1	Termografia Estática	10
3.1.2	Termografia Dinâmica	10
3.2	Registro de Imagens	11
3.2.1	Métricas de similaridade	12
3.2.1.1	Correlação Cruzada Normalizada	12
3.2.2	Transformação	13
3.2.2.1	Transformações FFD baseadas em <i>B-Splines</i> cúbicas	13
3.2.3	Interpolador	14
3.2.3.1	Interpolador Linear	15
3.2.4	Otimizador	15
3.2.4.1	LBFGS	15
3.3	Matrizes de Coocorrência de Níveis de Cinza	15
3.3.1	Construção de uma GLCM	16
3.3.2	GLCM Normalizada	16
3.3.3	Características de Textura	16
3.4	Redução de Dimensionalidade	17
3.4.1	Análise de Componentes Principais	17
3.4.2	Análise Discriminante Linear	19
3.5	Máquinas de Vetor de Suporte	22
4	METODOLOGIA	26
4.1	Aquisição de Imagens	26
4.2	Registro das Imagens	27
4.3	Extração da Região de Interesse	28
4.4	Extração de características	28
4.5	Redução de Características	32
4.6	Classificação	32
5	RESULTADOS PARCIAIS	33
6	CRONOGRAMA DO PLANO DE TRABALHO	34
7	CONCLUSÃO	35

7.1	Trabalhos Futuros	35
	REFERÊNCIAS	36

1 Introdução

O câncer de mama é o tipo mais comum entre as mulheres em todo o mundo, respondendo por 25% dos casos a cada ano (INCA, 2016). Quando diagnosticado tardiamente, as chances de cura são extremamente reduzidas, tornando o diagnóstico precoce um dos fatores mais importantes na redução da taxa de mortalidade desse tipo de doença.

A incidência câncer de mama aumenta em paralelo com o aumento da faixa etária, sendo que mulheres acima de 50 anos são mais suscetíveis ao desenvolvimento da patologia. No entanto, existem outros fatores de risco que implicam numa maior chance de aparecimento, como o histórico desse tipo de câncer na família, gestação tardia, terapia de reposição hormonal e exposição à radiação.

Os exames mais tradicionais na detecção do câncer de mama são os exames de toque e a mamografia. O exame de toque é um exame de triagem, onde a própria mulher pode procurar por nódulos nos seios. Porém, nem sempre o câncer resulta em aparecimento de nódulos. Dessa forma, a mamografia se tornou um exame essencial nos dias de hoje, pois utiliza os raios-x para detectar regiões de alta densidade nas mamas.

Apesar de ser o tipo de exame mais recomendado pelos especialistas, a mamografia é suscetível a falhas, já que mamas com alta densidade apresentam um grau de dificuldade elevado na detecção de tumores, que podem ficar escondidos pelo tecido denso da mama. Mulheres jovens geralmente apresentam alta densidade nas mamas, tornando a mamografia um exame não recomendável para essa faixa etária, pois utiliza a radiação na geração das imagens, o que pode futuramente causar o aparecimento do câncer na paciente. Dessa forma é necessário que outros tipos de exames sejam utilizados como forma de prevenção e diagnóstico precoce.

A termografia mamária é um exame de imagem não radioativo capaz de auxiliar médicos especialistas na detecção de tumores que não seriam possíveis de descobrir através da mamografia. Esse tipo de exame utiliza a radiação infravermelha, emitida naturalmente pelo corpo da paciente, para detectar anomalias no padrão de temperatura das mamas, que pode indicar o aparecimento de alguma doença.

Regiões próximas a um tumor tendem a ter um aumento na vascularização, ocorrendo uma maior circulação de sangue na região, que causará um aumento de temperatura em relação as outras regiões da mama. Esse aumento de temperatura é detectável através da termografia, permitindo que especialistas detectem a formação de um tumor antes mesmo que ele seja palpável.

Existem duas formas na obtenção de exames de termografia mamária. A primeira delas é a termografia estática, onde apenas uma imagem da paciente é gerada e analisada. A segunda forma é a chamada termografia dinâmica, onde várias imagens sequenciais são geradas, permitindo que o especialista analise a evolução na distribuição de calor nas mamas da paciente. A metodologia proposta utiliza as termografias dinâmicas para auxiliar médicos especialistas no diagnóstico precoce do câncer de mama.

A motivação deste trabalho é ajudar médicos especialistas no diagnóstico precoce do câncer de mama, portanto qualquer informação que possa discriminar mamas saudáveis de mamas doentes é relevante. Várias técnicas de Processamento de Imagens e Aprendizado de Máquina são utilizadas para aumentar o nível de informação que uma termografia pode dar ao especialista.

Durante um exame de termografia dinâmico, a paciente executa movimentos involuntários, causados pela respiração e pelo ajuste de postura, fazendo que as imagens sequenciais do exame não se

encaixem perfeitamente, causando um erro que pode influenciar na metodologia.

O registro de imagens deformável por *B-Splines* é utilizado para efetuar a correção desse erro. Posteriormente, extrai-se as regiões de interesse do exame, que são as mamas da paciente. Essa extração é feita de forma manual através de um aplicativo, onde o especialista deverá demarcar a região da mama.

Logo após, a etapa de extração de características é executada, onde os pixels de mesma posição e diferentes tempos da termografia são analisados como uma série de tempo, produzindo um conjunto de valores estatísticos para cada pixel, formando novas imagens a partir da termografia dinâmica original. A partir dessas imagens geradas, são extraídas o conjunto de características de textura a partir de matrizes de coocorrência.

Essas características podem ser reduzidas através de técnicas de redução de características como a técnica de Análise dos Componentes Principais e a Análise Discriminante Linear. No final do processo, as características reduzidas irão servir de entrada para uma Máquina de Vetor de Suporte que irá ser responsável por classificar as pacientes em saudável e com anomalia.

2 Objetivos

2.1 Objetivos Gerais

Desenvolver uma metodologia computacional que analise um exame termográfico dinâmico das mamas, a fim de encontrar padrões que diferenciem mamas saudáveis de mamas doentes.

2.2 Objetivos Específicos

Alguns objetivos extras são necessários para completar os objetivos gerais, sendo eles:

- Desenvolver técnicas que permitam a correção de postura em exames termográficos dinâmicos. Tais técnicas são conhecidas como registro de imagens, onde o resultado final pode variar muito de uma técnica utilizada para outra. Portanto, deve-se utilizar a que melhor se encaixe no problema.
- Analisar a variação de temperatura entre os diferentes tempos do exame, gerando características que sejam capazes de diferenciar os exames de pacientes saudáveis de exames de pacientes doentes.
- Utilizar as características extraídas para gerar uma Máquina de Vetor de Suporte, que seja capaz de classificar corretamente novos exames.

3 Fundamentação Teórica

Nesta seção, serão abordados os conceitos necessários para o entendimento da metodologia proposta.

3.1 A Termografia

A termografia é uma técnica que permite a visualização dos raios do espectro infravermelho de forma a mapear a temperatura de um objeto. A termografia infravermelha da mama, é um tipo de exame que detecta a radiação infravermelha emitida pela superfície da mama, produzindo um mapa de temperatura conhecido como termograma.

A grande vantagem deste tipo de exame em relação aos exames mais conhecidos, como a mamografia, é que este não utiliza radiação no processo de obtenção das imagens e também não causa incômodo físico ao paciente, pois não é necessário a compressão das mamas, como ocorre na mamografia.

Outro fator a se levar em consideração é o custo extremamente baixo e o fácil manuseio do equipamento necessário para obtenção do exame (BORCHARTT et al., 2013). A Figura 1 apresenta uma termografia em pseudo cor, onde a temperatura varia de acordo com a paleta de cores à direita da imagem.




Figura 1 – Termografia mamária.

Fonte: (SILVA et al., 2014)

3.1.1 Termografia Estática

A termografia estática (TI), é o tipo de termografia onde a medição de temperatura é feita uma única vez. No caso de TI das mamas são necessários procedimentos (SILVA et al., 2014) de preparação do ambiente e cuidados extras ao paciente para que o exame tenha resultado satisfatório, pois a condição da sala de exame, as loções corporais, o excesso de exposição ao sol e a estimulação das mamas antes do exame podem influenciar o resultado final (SILVA, 2015).

3.1.2 Termografia Dinâmica

A termografia dinâmica (TID), é um tipo de termografia onde a mediação de temperatura é realizada através de várias etapas de tempo, ou seja, a TID mede as mudanças de temperatura sobre um

determinado período de tempo. Originalmente conceituada por (ANBAR, 1987), onde notou-se que mudanças bruscas na temperatura da pele produziam informações valiosas, que não podem ser obtidas por meio de uma TI.

A TID apresenta uma característica importante na detecção de lesões mamárias, pois áreas saudáveis apresentam um comportamento distinto de áreas com algum tipo de patologia. Neoplasias são associadas com a angiogênese que causa um aumento de vascularização na região, sendo que, os vasos recém formados tendem a possuir poucas terminações nervosas, o que causa um comportamento irregular à estímulos externos, que é detectável através de um exame de termografia dinâmico (SILVA, 2015).

Na prática a TID monitora as mudanças na temperatura da pele, onde o estímulo térmico através de uma corrente de ar produz um contraste entre tecidos saudáveis e doentes. Regiões saudáveis da mama tendem a apresentar uma diminuição de temperatura com o estímulo de ar, enquanto as regiões doentes tendem a permanecer estáticas (AMALU, 2004).

3.2 Registro de Imagens

Quando imagens que foram extraídas entre diferentes tempos, pontos de vista ou aparelhos precisam ser comparadas, ocorre um problema de alinhamento das coordenadas dessas imagens. É necessário efetuar alguma forma de processamento para que essas imagens possam ser comparadas adequadamente. O *Registro de Imagens* é uma técnica que utiliza uma transformação T para mapear a posição e o valor de intensidade de um pixel p da imagem A para q na imagem B , como pode ser visto pela Equação 3.1. A Figura 2 mostra o efeito desse mapeamento.

$$T : p \rightarrow q \Leftrightarrow T(p) = q \quad (3.1)$$




Figura 2 – Registro de imagens é a tarefa de achar uma transformação espacial de uma imagem em outra.

Fonte: (IBANEZ et al., 2003)

Na literatura, é possível encontrar diversas definições para o problema de registro de imagens. De acordo com (BROWN, 1992), o processo de registro de imagens é transformação de conjuntos distintos de dados para um mesmo sistema de coordenadas. Em (CRUM; HARTKENS; HILL, 2014) é definido como um processo que determina correspondências entre as características de imagens extraídas em diferentes momentos, pontos de vista ou aparelhos. Tais correspondências podem ser utilizadas para aplicar transformações (rotação, translação, alongamento, etc.) em uma das imagens, de forma que seja possível a comparação entre as duas. A forma mais intuitiva de utilização do registro é para corrigir diferenças na posição entre varreduras. O registro de imagens adiciona valor à imagens, permitindo que imagens estruturais (CT, MR, ultrassom) e funcionais (PET, SPECT, funcional MRI) sejam vistas e analisadas no mesmo sistema de coordenadas, e facilita o uso de novas imagens, como para monitorar e quantificar a evolução de uma doença à medida que o tempo passa (CRUM; HARTKENS; HILL, 2014).

A Figura 3 mostra o fluxograma básico de um processo de registro de imagens. O conjunto de entrada básico de um processo de registro de imagens é composto por:

- Imagem fixa: imagem estática cujo espaço de coordenadas é o objetivo.
- Imagem móvel: imagem que será transformada para o espaço de coordenadas da imagem fixa.
- Transformação: função que irá ser responsável por mapear os pixels da imagem móvel na imagem fixa. Geralmente é responsável por dar nome ao registro.
- Métrica: uma medida que indica o quanto duas imagens são equivalentes.
- Interpolador: uma técnica para interpolar os valores da imagem móvel quando são remostrados através da transformação.
- Otimizador: o método utilizador para achar os melhores parâmetros da transformação que otimizam a métrica entre as duas imagens.




Figura 3 – Fluxograma do processo de registro de imagens.

Fonte: (PARRAGA, 2008)

3.2.1 Métricas de similaridade

As métricas de similaridade são provavelmente o elemento mais crítico no problema do registro de imagens, pois define o objetivo final do processo que é medir o quanto a imagem móvel é equivalente à imagem fixa após a transformação ser aplicada.

3.2.1.1 Correlação Cruzada Normalizada

A Correlação Cruzada Normalizada é uma métrica insensível à fatores multiplicativos entre as imagens. Produz uma função de custo com picos afiados e mínimos bem definidos. Por outro lado tem um raio de captura relativamente pequeno. Sua aplicação é limitada a imagens de mesma modalidade (adquiridas com o mesmo tipo de aparelho) (IBANEZ et al., 2003). A correlação cruzada normalizada é dada pela Equação 3.2:

$$C(f, m) = -1 \cdot \frac{\sum_{i=1}^N (f_i \cdot m_i)}{\sqrt{\sum_{i=1}^N f_i^2 \cdot \sum_{i=1}^N m_i^2}}, \quad (3.2)$$

onde f e m são os valores de pixels em forma de vetor das imagens fixa e móvel, respectivamente, i indica a posição do pixel em f e m , e N a quantidade pixels a ser considerado. Note que a equação é multiplicada por -1 . Esse fator é responsável por fazer o otimizador procurar os valores que mais se aproximem de 0, que é quando duas imagens são ditas equivalentes.

3.2.2 Transformação

A transformação é responsável por mapear os pixels da imagem móvel para a imagem fixa. Podemos dividir as transformações em dois conjuntos distintos, rígidas e deformáveis.

As transformações rígidas aplicam sobre a imagem móvel apenas transformações simples como operações de translação e rotação, dessa forma a imagem móvel não sofre deformações, sofrendo apenas o alinhamento de suas coordenadas. Registros que utilizam transformações rígidas são chamados de registro rígidos e na prática não são utilizados individualmente, pois não são capazes de corrigir erros locais que necessitam de transformações mais complexas para serem resolvidas. Apesar disso, são bastante utilizados como pré-processamento para os chamados registros deformáveis.

As transformações deformáveis são capazes de efetuar deformações nas imagens, dessa forma é possível corrigir erros que uma transformação rígida não é capaz de corrigir. Registro de imagens que utilizam esse tipo de transformação são geralmente chamados de registros não-rígidos ou deformáveis.

3.2.2.1 Transformações FFD baseadas em *B-Splines* cúbicas

Um dos tipos de transformações não-rígidas mais comuns atualmente são as chamadas transformações de deformação de forma livre (FFD) baseadas em *B-splines* cúbicas (YIN; HOFFMAN; LIN, 2009). A ideia básica desse tipo de transformação é manipular a grade de pixels a partir dos chamados pontos de controle. Essa manipulação permite criar um campo de deslocamento, que irá mapear os pixels da imagem móvel. A Figura 4 ilustra a idéia básica desse tipo de transformação, onde o campo de deslocamento é utilizado para mapear os pixels da imagem móvel, de forma que se assemelhem à imagem fixa.




Figura 4 – Campo de deslocamento da imagem móvel para a imagem fixa.

Fonte: (SCHWARZ, 2007)

Seja Φ a grade uniforme de dimensões $n_x \times n_y \times n_z$ com $\Phi_{i,j,k}$ representando o deslocamento do ijk -ésimo ponto de controle. O espaço entre as grades de controle nas direções x , y e z são denotadas por δ_x , δ_y e δ_z , respectivamente. A transformação $T(x : \Phi)$ é definida por

$$T(x : \Phi) = \sum_{l=0}^3 \sum_{m=0}^3 \sum_{n=0}^3 \beta_l(u) \beta_m(v) \beta_n(w) \Phi_{i+l, j+m, k+n}, \quad (3.3)$$

onde os parâmetros são dados por

$$i = \left\lfloor \frac{x}{\delta_x} \right\rfloor - 1, \quad (3.4)$$

$$j = \left\lfloor \frac{y}{\delta_y} \right\rfloor - 1, \quad (3.5)$$

$$z = \left| \frac{z}{\delta_z} \right| - 1, \quad (3.6)$$

$$u = \frac{x}{\delta_x} - (i + 1), \quad (3.7)$$

$$v = \frac{y}{\delta_y} - (j + 1), \quad (3.8)$$

$$w = \frac{z}{\delta_z} - (z + 1). \quad (3.9)$$

As funções β são *B-splines* cúbicas e definidas por

$$\beta_0(t) = (-t^3 + 3t^2 - 3t + 1)/6, \quad (3.10)$$

$$\beta_1(t) = (3t^3 - 6t^2 + 4)/6, \quad (3.11)$$

$$\beta_2(t) = (-3t^3 + 3t^2 + 3t + 1)/6, \quad (3.12)$$

$$\beta_3(t) = t^3/6, \quad (3.13)$$

onde $0 \leq t \leq 1$.

Um parâmetro muito importante desse tipo de transformação é a resolução da grade de controle, pois a partir dela serão gerados os campos de deslocamentos. Uma grade muito espaçosa permite a modelagem de transformações deformáveis globais, enquanto uma grade mais fina modela deformações altamente locais (YIN; HOFFMAN; LIN, 2009).

3.2.3 Interpolador

No processo do registro, a métrica geralmente compara os valores de intensidade dos pixels da imagem fixa com os pixels correspondentes na imagem móvel transformada. Quando transformamos um ponto de um espaço para o outro através de uma transformação, este geralmente irá ser mapeado para uma posição fora da grade de pixels da imagem (Figura 5). A função do interpolador é calcular o valor de intensidade em uma dada posição de forma correta (IBANEZ et al., 2003).




Figura 5 – Posições de grade da imagem fixa mapeadas para posições fora da grade na imagem móvel.

Fonte: (IBANEZ et al., 2003)

3.2.3.1 Interpolador Linear

O interpolador linear assume que os valores de intensidade dos pixels variam de forma linear entre as posições de grade. Dessa forma, os valores interpolados serão contínuos espacialmente, porém o gradiente de intensidade será descontínuo na grade. Se dois pontos conhecidos são dados por (x_0, y_0) e (x_1, y_1) a interpolação linear é dada pela Equação 3.14.

$$y = y_0 + (y_1 - y_0) \frac{x - x_0}{x_1 - x_0} \quad (3.14)$$

3.2.4 Otimizador

Como dito anteriormente, o papel do otimizador é encontrar os melhores parâmetros para a transformação escolhida no processo de registro de imagens. Dessa forma, um amplo conjunto de otimizadores podem ser utilizados, como os *Algoritmos Genéticos* (WHITLEY, 1994) e o *Gradiente Descendente* (BURGES et al., 2005).

3.2.4.1 LBFGS

O Limited-memory Broyden-Fletcher-Goldfarb-Shanno (LBFGS) é um método de otimização bastante comum em problemas de registro de imagens. De acordo com (SHEPPARD; TERRELL; HENKELMAN, 2008), é um método quasi-Newton que constrói informações sobre as segundas derivadas durante a otimização e utiliza essa informação para avançar em direção ao mínimo harmônico previsto. Mais especificamente, a inversa da matriz hessiana H^{-1} é construída iterativamente, começando a partir da matriz diagonal. O método pode ser utilizado de duas formas. Na primeira, uma direção de busca,

$$d_j = F_j H_j^{-1}, \quad (3.15)$$

é identificada em cada iteração, e a minimizador de linha é utilizado para avançar na direção,

$$R_{j+1} = R_j + \lambda d_j. \quad (3.16)$$

A segunda forma é utilizar H^{-1} diretamente para calcular o avanço,

$$R_{j+1} = R_j + F_j H^{-1}. \quad (3.17)$$

O LBFGS utiliza a memória da iteração anterior para construir H^{-1} . O número de iterações é um parâmetro variável e é definido pelo usuário.

3.3 Matrizes de Coocorrência de Níveis de Cinza

A análise de textura em imagens é uma técnica importante na identificação de características em imagens digitais. Uma das primeiras técnicas utilizadas para a extração dessas características foram as matrizes de coocorrências de níveis de cinza também chamadas de *GLCMs* (Gray Level Co-occurrence Matrix) originalmente propostas em (HARALICK; SHANMUGAM; DINSTEN, 1973). Desde então elas vem sendo bastante utilizadas em várias aplicações de análise de textura e permanecem sendo uma ferramenta importante no domínio de análise de texturas (SEBASTIAN et al., 2012).

A GLCM é uma técnica utilizada para extrair características estatísticas de textura de segunda ordem (ALBREGTSEN et al., 2008), ou seja, a medição considera a relação entre pares de pixels, geralmente vizinhos (HALL-BEYER, 2008).

3.3.1 Construção de uma GLCM

Seja I uma imagem em níveis de cinza e N a quantidade de níveis de cinza, uma GLCM G é uma matriz quadrada de ordem N (SEBASTIAN et al., 2012). O elemento da matriz $P(i, j | \Delta x, \Delta y)$ é a frequência relativa em que dois pixels de intensidade (i, j) , separados por uma distância $(\Delta x, \Delta y)$, são vizinhos. Também é possível dizer que o elemento $P(i, j | d, \theta)$ contém os valores da probabilidade de segunda ordem para mudanças entre os níveis de cinza i e j em uma distância d e um ângulo θ (ALBREGTSEN et al., 2008).

Seja I uma imagem de dimensões $W \times H$, então uma GLCM de I é definida pela Equação 3.18.

$$G(i, j | \Delta x, \Delta y) = \sum_{p=1}^W \sum_{q=1}^H A \quad (3.18)$$

$$A = \begin{cases} 1, & \text{se } I(p, q) = i \text{ e } I(p + \Delta x, q + \Delta y) = j \\ 0, & \text{caso contrário} \end{cases} \quad (3.19)$$

3.3.2 GLCM Normalizada

Considere $N = \sum_i \sum_j G_d(i, j)$ a quantidade ocorrências de pares em G_d . Seja $GN_d(i, j) = \frac{1}{N} G_d(i, j) \cdot N$, chamada de GLCM normalizada, onde as entradas (i, j) de $GN_d(i, j)$ são as probabilidades de coocorrência de um determinado pixel com intensidade i ser separado de um pixel de intensidade j por uma distância k em uma determinada direção d (SEBASTIAN et al., 2012).

3.3.3 Características de Textura

A partir de uma GLCM, é possível extrair um conjunto de características que descrevem a textura de determinada imagem (ALBREGTSEN et al., 2008), disponíveis em (HARALICK; SHANMUGAM; DINSTEIN, 1973; HARALICK, 1979; CONNERS; TRIVEDI; HARLOW, 1984). De acordo com (HALL-BEYER, 2008) temos as seguintes características que podem ser extraídas a partir de uma GLCM:

$$Constraste = \sum_{i,j=0}^{N-1} P_{i,j} (i - j)^2 \quad (3.20)$$

$$Dissimilaridade = \sum_{i,j=0}^{N-1} P_{i,j} |i - j| \quad (3.21)$$

$$Homogeneidade = \sum_{i,j=0}^{N-1} \frac{P_{i,j}}{1 + (i - j)^2} \quad (3.22)$$

$$ASM = \sum_{i,j=0}^{N-1} P_{i,j}^2 \quad (3.23)$$

$$Energia = \sqrt{ASM} \quad (3.24)$$

$$Correlação = \sum_{i,j=0}^{N-1} P_{i,j} \left[\frac{(i - \mu_i) \cdot (j - \mu_j)}{\sqrt{(\sigma_i^2) \cdot (\sigma_j^2)}} \right] \quad (3.25)$$

$$\mu_i = \sum_{i,j=0}^{N-1} i \cdot (P_{i,j}) \quad (3.26)$$

$$\mu_j = \sum_{i,j=0}^{N-1} j \cdot (P_{i,j}) \quad (3.27)$$

$$\sigma_i^2 = \sum_{i,j=0}^{N-1} P_{i,j} (i - \mu_i)^2 \quad (3.28)$$

$$\sigma_j^2 = \sum_{i,j=0}^{N-1} P_{i,j} (j - \mu_j)^2 \quad (3.29)$$

onde N é quantidade de níveis de cinza $P_{i,j}$ é a frequência de um par de pixels i e j serem vizinhos.

3.4 Redução de Dimensionalidade

Em *Aprendizado de Máquina*, geralmente existe um conjunto de dados previamente disponíveis. Nesse conjunto de dados, cada indivíduo é representado por um conjunto de características extraídas do dado original. Por exemplo, em imagens de níveis de cinza é possível extrair as características a partir de uma GLCM. A quantidade de características que um indivíduo possui é chamado de *dimensão*. Para um conjunto de dados de dimensão $D = 6$, então temos 6 características que descrevem cada indivíduo.

É fácil pensar que quanto maior o número de características, melhor para discriminar os indivíduos. Porém, um conjunto de dados com uma dimensão muito alta implica maior complexidade no problema de classificação. Outro problema é que, em muitos casos, nem todas as características são consideradas importantes para o entendimento de um certo problema (FODOR, 2002).

Em termos matemáticos, o problema de *Redução de Dimensionalidade* pode ser descrito da seguinte forma: Dado um conjunto dados com p dimensões $x = (x_1, x_2, \dots, x_p)^T$, encontrar uma representação de menor dimensão $s = (s_1, s_2, \dots, s_k)^T$, onde $k \leq p$, que seja capaz de capturar o conteúdo dos dados originais, de acordo com um critério preestabelecido (FODOR, 2002).

Algumas técnicas de redução de dimensionalidade são descritas abaixo.

3.4.1 Análise de Componentes Principais

A Análise de Componentes Principais (PCA) é uma técnica de redução linear (JACKSON, 2005). Por ser baseada na matriz de covariância dos dados, é um método de segunda ordem. O PCA reduz a dimensionalidade encontrando os *principais componentes* (PCs) do conjunto de dados com maior variância, que são vetores formados pelas combinações das características originais. Por exemplo, o primeiro PC é o que possui maior variância, Temos $s_1 = x^T w_1$, onde o vetor de coeficientes de p dimensões é $w_1 = (w_{1,1}, \dots, w_{1,p})^T$ que resolve:

$$w_1 = \arg \max_{\|w=1\|} Var\{x^T w\} \quad (3.30)$$

O segundo PC é a combinação linear com a segunda maior variância e ortogonal ao primeiro PC, e assim sucessivamente. Existem tantos PCs quanto o número de características originais (FODOR, 2002).

Geralmente, normaliza-se os dados antes da aplicação do PCA, pois o método é dependente da escala. Um dos métodos possíveis para a normalização é escalar cada características entre 0 e 1. Então, assumindo que os dados estão normalizados, calcula-se a matriz de covariância

$$C = \frac{1}{p-1} \sum_{i=1}^p (x_i - \bar{x}) \cdot (x_i - \bar{x})^T, \quad (3.31)$$

onde \bar{x} é o vetor médio dado por

$$\bar{x} = \frac{1}{p} \sum_{i=1}^p x_i. \quad (3.32)$$

Utilizando a relação

$$Cv = \lambda v, \quad (3.33)$$

onde v é um autovetor de C e λ o seu respectivo autovalor. Cada autovetor corresponde a um PC, e os respectivos autovalores indicam o grau de variância de cada PC. Assim, escolhendo os k PCs com maior variância absoluta, podemos mapear os dados originais em um novo conjunto

$$S = W^T X, \quad (3.34)$$

onde X é o conjunto de dados originais e W uma matriz de transformação

$$W = (v_1, \dots, v_k), \quad (3.35)$$

onde v_1 é o PC de maior variância e v_k o k -ésimo PC de maior variância.

É uma técnica muito útil quando as características originais não oferecem muita variação nos dados, transformando o conjunto em um novo espaço com menor dimensão onde as novas características possuem uma melhor dispersão. A Figura 6 mostra um conjunto de indivíduos gerados por distribuições normais multivariadas com 3 características. Utilizando o PCA para reduzir o espaço tridimensional para bidimensional, temos a Figura 7, que exemplifica o efeito da redução.




Figura 6 – Amostras geradas utilizando um distribuição normal multivariada.

Fonte: Elaborada pelo autor




Figura 7 – Amostras reduzidas para o espaço bidimensional utilizando os dois principais componentes.

Fonte: Elaborada pelo autor

3.4.2 Análise Discriminante Linear

A Análise Discriminante Linear (LDA) é uma técnica similar ao PCA, onde combinações lineares das características são utilizadas para formar um novo espaço de dimensões reduzidas. A diferença é que ao contrário do PCA que busca combinações com maior variância entre os dados, o LDA procura combinações que melhor separam as classes de um determinado problema, portanto podemos dizer que o LDA é uma técnica supervisionada, pois precisamos conhecer as classes que cada indivíduo pertence.

Normalmente é utilizado para redução de dimensionalidade, como um pré-processamento de técnicas de aprendizado de máquina e reconhecimento de padrões (RASCHKA, 2014). Também é possível utilizar o LDA como um classificador.

Foi originalmente proposto em (FISHER, 1936) como um problema *2-class*, que foi generalizado para um problema *multi-class* em (RAO, 1948).

Considerando um conjunto de observações X de dimensões $k \times p$, em que k corresponde à quantidade de indivíduos e p à quantidade de características de cada indivíduo. Para cada indivíduo em X , existe um elemento em y que indica a classe ao qual pertence. O objetivo é encontrar uma transformação W , que maximize a distância entre classes (Figura 9) e minimize a distância intra-classe (Figura 8).




Figura 8 – Distância intra-classe.

Fonte: Elaborada pelo autor




Figura 9 – Distancia inter-classes.

Fonte: Elaborada pelo autor

A transformação linear W mapeia X em \bar{X} através da Equação 3.36

$$\bar{X} = W^T \cdot X \quad (3.36)$$

onde W é formado pelos m autovetores com maiores autovalores absolutos da matriz S dada pela Equação 3.37. Uma observação importante é que $m < c - 1$, onde c é a quantidade de classes que existem em y (RASCHKA, 2014).

$$S = S_W^{-1} \cdot S_B \quad (3.37)$$

A matriz S_W é chamada de matriz de dispersão intra-classe e é definida por:

$$S_W = \sum_{i=1}^c S_i \quad (3.38)$$

$$S_i = \sum_{x \in c_i}^n (x - \mu_i) \cdot (x - \mu_i)^T \quad (3.39)$$

$$\mu_i = \frac{1}{n_i} \sum_{x \in c_i}^n x_k \quad (3.40)$$

onde, S_i é matriz de dispersão da classe c_i e μ_i é o vetor que representa os valores médios de cada característica de indivíduos que pertencem a classe c_i .

A matriz S_B é chamada de matriz de dispersão inter-classes e é definida por:

$$S_B = \sum_{i=1}^c N_i (\mu_i - \mu) \cdot (\mu_i - \mu)^T \quad (3.41)$$

onde, N_i é a quantidade de indivíduos que pertencem a classe c_i e μ é o vetor que representa a média das características de todos os indivíduos em X .

A vantagem de utilizar o LDA é que problema de classificação é simplificado pela criação de novas características a partir das originais, que melhor separam as classes do conjunto de dados.

A grande desvantagem é que não é possível saber quais características originais tem maior peso, pois os discriminantes são formados a partir de combinações lineares de todas elas.

A Figura 10 apresenta um conjunto de indivíduos que pertencem a três classes distintas. Cada classe foi gerada a partir de uma distribuição normal multivariada, onde os parâmetros diferem entre elas. A Figura 11 apresenta o resultado da aplicação do LDA para efetuar a redução do espaço tridimensional para bidimensional.




Figura 10 – Amostras geradas de distribuições normais multivariadas.

Fonte: Elaborada pelo autor




Figura 11 – Resultado da aplicação do LDA para reduzir as amostras da Figura 10.

Fonte: Elaborada pelo autor

3.5 Máquinas de Vetor de Suporte

Problemas de classificação geralmente envolvem classificar se um certo indivíduo pertence à classe A , B ou C . Atualmente existem diversas técnicas de aprendizado de máquina capazes de realizar essa tarefa com êxito e umas das principais técnicas utilizadas hoje em dia são as Máquinas de Vetor de Suporte (SVM).

Foram originalmente propostas por (CORTES; VAPNIK, 1995) como um classificador binário, capaz de dizer se um determinado indivíduo pertence à classe A ou B .

São parte do grupo de técnicas de aprendizado supervisionado, onde é necessário conhecer previamente um conjunto de indivíduos para que o algoritmo gere um modelo capaz de prever qual a classe de uma nova entrada.

Uma SVM constrói hiperplanos em um espaço de alta dimensão, que pode ser utilizado para a tarefa de classificação. Uma boa separação é obtida através do hiperplano que possui maior distância entre os pontos mais próximos de cada classe no conjunto de dados de treino (LEARN, 2016). A Figura 12 mostra hiperplanos gerados por uma SVM.




Figura 12 – Construção de hiperplanos.

Fonte: (LEARN, 2016)

De acordo com (SILVA, 2015), dado (x_k, y_k) o conjunto de amostras para treinamento, sendo que $x_i \in \mathbb{R}^n$ correspondente ao vetor de características do indivíduo i , $y_i \in \{1, -1\}$ corresponde à classe do indivíduo i , sendo $i = 1, 2, \dots, k$. O objetivo do problema de classificação é encontrar uma função $f(x) : \mathbb{R}^n \rightarrow \{1, -1\}$ que seja capaz de estimar corretamente a classe do indivíduo x .

Na etapa de treinamento a função $f(x) = (w \cdot x) + b$ é estimada, de forma que a seguinte relação seja satisfeita:

$$y_i((w \cdot x_i) + b) \geq 1 \quad (3.42)$$

onde w é o vetor normal ao hiperplano e b a distância da função f em relação à origem. Os valores ótimos de w e b são encontrados de acordo com a restrição dada pela Equação 3.42 ao minimizar a equação:

$$\phi(w) = \frac{w^2}{2} \quad (3.43)$$

O SVM possibilita encontrar um hiperplano que minimize a ocorrência de erros nos casos em que a separação ótima entre as classes não seja possível. Com a utilização de variáveis de folga, é possível relaxar a restrição da Equação 3.42, resolvendo:

$$\min \phi(w, \zeta) = \frac{w^2}{2} C \sum_{i=1}^N \zeta_i \quad (3.44)$$

sujeito a:

$$y_i((w \cdot x_i) + b) + \zeta_i \geq 1 \quad (3.45)$$

onde C é um parâmetro de treinamento que define o equilíbrio entre a complexidade do modelo e o erro de treinamento.

Utilizando a teoria dos multiplicadores de Lagrange é possível obter:

$$L(a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i,j=1}^N a_i a_j y_i y_j (x_i, x_j) \quad (3.46)$$

Assim, o objetivo é encontrar os multiplicadores de Lagrange a_i ótimos que satisfaçam a Equação 3.47 (CHAVES, 2006).

$$\sum_{i=1}^N a_i y_i = 0, \quad 0 \leq a_i \leq C \quad (3.47)$$

Apenas os pontos onde a restrição imposta pela Equação 3.42 é igual 1, tem correspondentes $a_i \neq 0$. Esses pontos são chamados de vetores de suporte, e estão geometricamente sobre as margens, possuindo grande importância na definição do hiperplano ótimo, pois delimitam as margens do conjunto de treinamento. Na Figura 13, os vetores de suporte são representados por círculos circunscritos.




Figura 13 – Vetores de suporte.

Fonte: Elaborada pelo autor

Pontos além da margem não tem influência suficiente para determinar o hiperplano, porém os vetores de suporte são essenciais nessa tarefa.

Considere o conjunto de amostras da Figura 14. Não é possível traçar uma reta capaz de separar as classes, tornando o problema um caso não-linear. De acordo com (SILVA, 2015), é necessário uma transformação não-linear capaz de mapear o conjunto original (espaço dados) para um novo espaço (espaço de características).

Esse novo espaço deve apresentar dimensões suficientes para que seja possível realizar a separação linear do conjunto de dados. Dessa forma, o hiperplano de separação é definido como uma função linear de vetores retirados do espaço de características e não do espaço de dados. A construção desse conjunto depende de uma função K , chamada de *kernel* (HAYKIN, 2001). A Equação 3.48 apresenta a forma modificada da Equação 3.47 utilizando uma função K .




Figura 14 – Conjunto de indivíduos não separáveis linearmente.

Fonte: Elaborada pelo autor

$$L(a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i,j=1}^N a_i a_j y_i y_j K(x_i, x_j) \quad (3.48)$$

Um conjunto de funções amplamente utilizadas em conjunto com uma SVM para classificação de dados não linearmente separáveis são as funções de base radial (RBF). Uma função RBF é definida por:

$$K(x_i, y_i) = \exp(-\gamma \|x_i - y_i\|^2) \quad (3.49)$$

onde $\gamma = 1/\sigma^2$, onde σ é a variância.

4 Metodologia

Nesta seção, são apresentados os procedimentos propostos para a realização dos objetivos descritos na Seção 2. A Figura 15 apresenta o fluxo das etapas executadas.




Figura 15 – Fluxograma da metodologia.

Fonte: Elaborada pelo autor

4.1 Aquisição de Imagens

A aquisição de imagens é uma etapa crucial na metodologia proposta, pois sem imagens para casos de teste não é possível validar a metodologia. Atualmente existem poucos bancos de imagem termográficas mamárias disponíveis para o público geral, sendo a maioria deles de propósito privado. As imagens utilizadas neste trabalho são provenientes do *Database for Mastology Research with Infrared Image - DMR-IR*, acessível através da interface on-line <<http://visual.ic.uff.br/dmi>>. Mais informações sobre a base de imagens utilizada podem ser encontradas em (SILVA et al., 2014).

De acordo com (SILVA et al., 2014), no protocolo de termografias dinâmicas as pacientes são submetidas a um estresse térmico causado pela refrigeração por um ventilador elétrico. Quando a média de temperatura entre as mamas é de 30.5°C (Figura 16), ou 5 minutos de estresse foram aplicados, a refrigeração é interrompida e a aquisição sequencial das imagens é iniciada, extraindo um total de 20 imagens sequenciais com intervalos de tempo fixos.




Figura 16 – Monitoramento da temperatura média para começar a aquisição sequencial.

Fonte: (SILVA et al., 2014)

As imagens utilizadas possuem dimensão de 640 pixels de largura e 480 pixels de altura e foram utilizados os valores de temperatura (em graus celsius) obtidos diretamente da câmera termográfica utilizada na aquisição.

No total foram utilizados 70 exames previamente diagnosticados para aplicação desta metodologia, sendo que 35 são de pacientes saudáveis e os 35 restantes de pacientes que apresentam algum tipo de anomalia nas mamas.

4.2 Registro das Imagens

Durante o protocolo de aquisição de imagens, é natural que a paciente execute movimentos involuntários causados pela respiração e ajuste de postura. Esses movimentos causam diferenças espaciais de uma sequência para a outra. As Figuras 17a e 17b são termogramas sequências de tempos $t = 1$ e $t = 2$, respectivamente. A Figura 17c apresenta a diferença quadrática $d = (P_t(i, j) - P_t(i, j))^2$, onde (i, j) é a posição do pixel, sendo $i = 0, \dots, 639$ e $j = 0, \dots, 479$, e $P_t(i, j)$ é o valor de pixel na posição (i, j) no tempo t . É possível notar que existe uma diferença causada pela movimentação involuntária da paciente.




Figura 17 – Termogramas de tempos distintos. Tons mais claros denotam uma maior diferença entre as regiões.

Fonte: Elaborada pelo autor.

Para analisar as sequências de termogramas de um determinado exame é necessário corrigir essas diferenças, dessa forma o registro de imagens é uma etapa essencial de pré-processamento das termografias. Para a construção do registro, as seguintes técnicas foram utilizadas:

- Métrica: Correlação Cruzada Normalizada (Capítulo 3.2)
- Transformação: *B-Splines* (Capítulo 3.2.2.1)
- Interpolador: Linear (Capítulo 3.2.3.1)
- Otimizador: LBFGS (Capítulo 3.2.4.1)

Utilizando a primeira sequência do conjunto de termograma como imagem fixa, executamos o algoritmo de registro 19 vezes, sendo que as sequências restantes são as imagens móveis. Após a aplicação do registro, os erros de postura são corrigidos, permitindo que as sequências de uma TID sejam analisadas e comparadas.

4.3 Extração da Região de Interesse

Essa etapa consiste em extrair a região de interesse (ROI) da imagem. Como a metodologia tem o objetivo de detectar anomalias no padrão de vascularização das mamas, é de interesse que as demais regiões de uma TID sejam excluídas do processo.

Alguns métodos de segmentação automática são encontrados na literatura (MARQUES, 2012), porém existem limitações que não tornam possíveis a utilização desse tipo de técnica. Dessa forma, a região de interesse é extraída de forma manual, através da utilização de um programa de visualização e edição de imagens.

Apesar de cada TID possuir um total de 20 sequências de termogramas, utilizamos apenas a sequência no tempo inicial para gerar uma máscara responsável por demarcar a ROI segmentada manualmente através do software ImageJ (ABRÀMOFF; MAGALHÃES; RAM, 2004; RASBAND; IMAGEJ et al., 1997).

Utilizando a máscara da sequência inicial é possível extrair as ROIs das demais sequências após a aplicação do registro dos termogramas (Capítulo 4.2). A Figura 18a demonstra a etapa de segmentação manual utilizando o mouse para desenhar o polígono que definirá a ROI. Como resultado uma máscara binária (Figura 18b) é gerada, para ser utilizada como ROI para todas as 20 sequências de termogramas em uma TID.




Figura 18 – Extração da região das mamas através do software ImageJ.

Fonte: (SILVA, 2015)

4.4 Extração de características

Dado um exame TID, temos 20 sequências de termogramas, cada um correspondendo à um tempo distinto em ordem sequencial. Precisamos extrair características que diferenciem as TID de pacientes saudáveis de TID de pacientes com algum tipo de anomalia.

Dado o vetor $p = [I_1(i, j), I_2(i, j), \dots, I_{20}(i, j)]$, onde $I_t(i, j)$ é o valor de temperatura do termograma de tempo t na posição (i, j) , é possível extrair 4 valores estatísticos de p , sendo eles:

- A temperatura de inicial, ou seja, o valor de $I_1(i, j)$. Nota-se que a temperatura inicial da sequência de termogramas oferece uma boa discriminação, pois regiões com anomalias tendem a ficar mais definidas durante o processo de resfriamento e não possuem regiões equivalentes na mama oposta. A Figura 19 mostra a diferença entre uma TID saudável e outra com anomalia.

- O ganho de temperatura total dado por $G = I_{20}(i, j) - I_1(i, j)$. Essa medida informa o quanto uma dada região se aqueceu ou esfriou durante o tempo de aquisição dos termogramas. Durante os testes realizados, foi possível notar que regiões com algum tipo de anomalia tendem a ganhar mais temperatura durante o tempo de extração das imagens. Em imagens saudáveis quando ocorre esse tipo de comportamento, geralmente existe um tipo de espelhamento, de forma que ele aparece nas duas mamas. Na Figura 20a vemos uma TID de paciente saudável, onde existe um aspecto simétrico entre as regiões. A Figura 20b possui uma região de alto ganho de temperatura em relação as demais da mama, coincidindo com a região do tumor.
- O ganho médio de temperatura entres os tempos dado pela Equação 4.1. Essa característica se assemelha ao ganho total de temperatura, onde regiões com algum tipo de anomalia tendem ter uma média maior que as demais regiões e não apresentam uma similaridade na mesma região da outra mama. A Figura 21 apresenta o resultado da extração dessa característica em TID de paciente saudável e em uma TID de paciente doente.
- O desvio padrão do ganho de temperatura entres os tempos dada pela Equação 4.2. Essa característica apresenta um grande fator de discriminância entres regiões saudáveis e com anomalias. Regiões saudáveis tendem a ganhar temperatura de forma uniforme durante a aquisição dos termogramas, ao contrário de regiões que possuem anomalia, que variam bastante no ganho de temperatura. Dessa forma regiões saudáveis apresentam um valor para S mais baixo em relação à regiões que possuem algum tipo de anomalia. A Figura 22 apresenta o desvio padrão do ganho de temperatura em uma TID de paciente saudável e em uma TID de paciente doente.

Abaixo temos as definições dos valores utilizados:

$$M = \frac{1}{N} \cdot \sum_{t=2}^N I_t(i, j) - I_{t-1}(i, j), \quad (4.1)$$

$$S = \sqrt{\frac{1}{N} \cdot \sum_{t=2}^N ((I_t(i, j) - I_{t-1}(i, j)) - M)^2}, \quad (4.2)$$

onde M é o ganho médio entre os tempos, S o desvio padrão entre os tempos e N a quantidade de tempos a ser considerado.

Essas características quando analisadas em conjunto oferecem um grande discriminador entre as pacientes. Em uma paciente saudável, é possível perceber a similaridade entre as mamas direita e esquerda como nas Figuras 19a, 20a e 21a, e uma homogeneidade no desvio padrão como na Figura 22b.

Em uma mama com algum tipo de anomalia, nota-se uma assimilaridade entre as mamas, como nas Figuras 19b, 20b e 21b e uma maior heterogeneidade para o desvio padrão, como na Figura 22b temos regiões com uma maior desvio padrão em relação as demais regiões da mama, coincidindo com as regiões de maior pico nas imagens das outras características.




Figura 19 – Temperatura Inicial. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante, onde a região demarcada infoma a localização.

Fonte: Elaborada pelo autor




Figura 20 – Ganho de temperatura total. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante. A região mais avermelhada em (b) coincide com a região em que o tumor aparece.

Fonte: Elaborada pelo autor




Figura 21 – Ganho de temperatura média entre os tempos da TID. Em (a) vemos um exame de paciente saudável, enquanto em (b) temos uma paciente com lesão na mama.

Fonte: Elaborada pelo autor




Figura 22 – Desvio padrão do ganho de temperatura entre os tempos da TID. Em (a) vemos um exame de paciente saudável, enquanto em (b) temos uma paciente com lesão na mama, onde a região demarcada informa a região do tumor.

Fonte: Elaborada pelo autor

A partir das imagens geradas acima, são extraídas um conjunto de características de textura baseadas em GLCM, definidas pelas Equações 3.20,3.21,3.22,3.23,3.24 e 3.25 mostradas no Capítulo 3.3.

Antes de gerarmos as GLCM é necessário converter a escala de valores para níveis de cinza. Essa conversão é obtida através de

$$X' = a - \frac{(X - X_{min})(b - a)}{X_{max} - X_{min}}, \quad (4.3)$$

onde X é o conjunto de valores, X_{min} o menor valor do conjunto, X_{max} o maior valor, b o valor máximo desejado e a o valor mínimo desejado. No caso das imagens extraídas na Seção 4.4 temos $a = 0$ e $b = 255$, dessa forma serão convertidas em níveis de cinza.

A partir da conversão podemos extrair as GLCM. No total são geradas 4 matrizes para cada imagem, com distâncias $(\Delta x = 1, \Delta y = 0)$, $(\Delta x = 1, \Delta y = 1)$, $(\Delta x = 0, \Delta y = 1)$ e $(\Delta x = -1, \Delta y = 1)$. A partir daí serão geradas as 6 características citadas acima, formando um total de 96 características que serão utilizadas na etapa de classificação da metodologia.

4.5 Redução de Características

Essa etapa consiste em reduzir o conjunto de 96 características previamente extraídas para um conjunto menor e mais conciso de características. Utilizando os 3 métodos descritos no Capítulo 3.4, transforma-se o conjuntos de dados originais em conjuntos distintos que serão analisados individualmente na etapa de classificação, sendo eles:

- PCA com $C = 30$, que projeta o conjunto de características em um novo espaço de 30 dimensões.
- PCA com $C = 20$, que projeta o conjunto de características em um novo espaço de 20 dimensões.
- LDA com $C = 1$, que projeta o conjunto de características em um novo espaço de 1 dimensão.
- Combinação do PCA e LDA, onde o PCA com $C = 40$ é aplicado, reduzindo o espaço para 40 dimensões e em seguida o LDA com $C = 1$ é utilizado, reduzindo o espaço para 1 dimensão.

4.6 Classificação

Essa etapa consiste em classificar um determinado exame TID em saudável ou com algum tipo de anomalia. São utilizadas as características extraídas no Capítulo 4.4 como entrada para uma SVM.

Durante essa etapa, o conjunto de características originais são subdividas em 2 conjuntos distintos que chamadas de base de treino e teste, que não possuem indivíduos em comum entre eles. Antes do treinamento de uma SVM, transforma-se o espaço de características através de um dos métodos descritos no Capítulo 4.5. Essa transformação é calculada a partir da base de treino e depois aplicada em ambas as bases, de forma que a base de teste não tem influência na geração da transformação.

Na etapa de treinamento, a base de treino juntamente com seus valores de classe é utilizada para encontrar os melhores vetores de suporte para a SVM.

Após o termino do treinamento, a validação do modelo é executada, onde utilizamos a base de teste sem os valores de classe como entrada no modelo gerado, que irá classificar os indivíduos existentes na base.

Os resultados são comparados com os valores de classe conhecidos para validação do modelo. São extraídos os valores de acurácia (Equação 4.4) que mede a taxa de acerto geral, a sensibilidade (Equação 4.5) que mede a taxa de acerto para os casos que possuem anomalia e a especificidade (Equação 4.6) que mede a taxa de acerto de casos saudáveis.

$$Acurácia = \frac{TP + TN}{TP + FP + TN + FN} \quad (4.4)$$

$$Sensibilidade = \frac{TP}{TP + FN} \quad (4.5)$$

$$Especificidade = \frac{TN}{TN + FP} \quad (4.6)$$

onde TP, TN, FP e FN são as quantidades de verdadeiro positivo, verdadeiro negativo, falso positivo e falso negativo, respectivamente.

5 Resultados Parciais

Nesse capítulo são apresentados os resultados parciais da aplicação da metodologia para a classificação de termografias dinâmicas em saudável e com anomalia.

Os teste são aplicados 100 vezes consecutivas e a média dos resultados é analisada. Em cada teste, a base é inicialmente dividida em 80% dos casos para o treinamento do SVM e 20% para validação do modelo. Os indivíduos são selecionados aleatoriamente de forma que a proporção entre as classes seja mantida. Como a base utilizada apresenta balanceamento de 1:1 entre as classes, não ocorre o desbalanceamento na etapa de treinamento e validação.

Após a divisão das bases, as técnicas de redução de dimensionalidade é utilizada, onde a base de treino é utilizada como referência para a análise de quais características são as mais eficientes. As técnicas de redução utilizadas são as descritas na Seção 4.5. Então a base de treino é utilizada para gerar o modelo SVM, que posteriormente será utilizado na classificação dos indivíduos. A Tabela 1 apresenta os resultados parciais da metodologia.

Método	Acurácia	Sensibilidade	Especificidade
Sem redução	42,4%	23,7%	68,9%
PCA, $C=30$	48,2%	44,1%	52,2%
PCA, $C=20$	47,5%	44,7%	54,4%
LDA, $C=1$	78,3%	79,9%	76,7%
PCA+LDA, $C_1=40$, $C_2=1$	82,5%	84,1%	81,0%

Tabela 1 – Média final da execução dos testes 100 vezes para cada método de seleção de características.

Analisando a Tabela 1, vemos que a estratégia sem reduzir as características não apresenta bom resultado, ficando abaixo dos 50% de acurácia. A utilização do PCA também não mostrou grande melhora nos resultados.

A técnica de redução que obteve um bom resultado foi a LDA, que sozinha demonstrou ser a melhor para a redução das características. No entanto, a combinação da aplicação do PCA seguida da aplicação do LDA foi a que demonstrou melhores resultados nos testes realizados até o momento, onde a acurácia, sensibilidade e especificidade ficaram acima dos 80%.

Como o PCA e LDA são técnicas que transformam o conjunto de características em um novo espaço a partir de vetores formados por combinação linear de todas as características, não é possível obter as melhores características,

Um fator que contribui bastante para os resultados abaixo do esperado é a quantidade de exames disponíveis. A base utilizada é relativamente pequena em comparação com bases utilizadas por metodologias baseadas em mamografia, que chegam a possuir mais de 3000 mil exames disponíveis para os pesquisadores. Apesar disso, os resultados demonstrados são promissores e com a utilização de outras características que possam discriminar as classes é possível que melhores resultados sejam obtidos.

6 Cronograma do Plano de Trabalho

A plano de trabalho na elaboração da metodologia pode ser subdividido em:

1. Pesquisa Bibliográfica
2. Coleta de Dados
3. Elaboração do Projeto de Monografia
4. Revisão Gramatical e Ortográfica
5. Defesa de Monografia

A Tabela 2 apresenta o cronograma de execução das atividades.

Etapas	09/2015	10/2015	11/2015	12/2015	01/2016	02/2016	03/2016	04/2016
1	X	X	X					
2			X	X				
3				X	X	X	X	
4							X	
5								X

Tabela 2 – Cronograma do plano de trabalho.

7 Conclusão

A metodologia apresenta uma forma de auxiliar médicos especialistas na detecção do câncer de mama. O objetivo não é indicar o local suspeito, apenas dizer se um determinado paciente apresenta ou não algum tipo de anomalia na região das mamas.

A termografia é um exame que não deve ser utilizado isoladamente para a detecção desse tipo de câncer, mas em conjunto com outros tipos de exame, como a mamografia. A vantagem desse tipo de imagem é que o equipamento utilizado para extração das imagens é fácil de carregar, permitindo a locomoção para diferentes lugares. Apesar disso, é necessário um ambiente controlado na etapa de extração das imagens.

O resultados apresentados pela metodologia demonstram ser promissores, com 82,5% de acurácia, 84,1 % de sensibilidade e 81,0% de especificidade.

7.1 Trabalhos Futuros

O maior impasse na metodologia é pequena base de imagens previamente diagnosticadas disponível. Foram utilizadas apenas 70 imagens na metodologia, longe da quantidade ideal para algoritmos de aprendizado de máquina. Com a obtenção de novas imagens é possível conseguir melhores resultados.

Novas métricas também podem ser estudadas, com o objetivo de incluí-las na metodologia apresentada, deixando-a mais robusta e mais precisa.

Referências

INCA. *Mama*. 2016. <<http://www2.inca.gov.br/wps/wcm/connect/tiposdecancer/site/home/mama>>. Acessado em: 05/03/2016.

BORCHARTT, T. B. et al. Breast thermography from an image processing viewpoint: A survey. *Signal Processing*, Elsevier, v. 93, n. 10, p. 2785–2803, 2013.

SILVA, L. et al. A new database for breast research with infrared image. *Journal of Medical Imaging and Health Informatics*, American Scientific Publishers, v. 4, n. 1, p. 92–100, 2014.

SILVA, L. F. D. *Uma Análise Híbrida para Detecção de Anomalias da Mama usando Séries Temporais de Temperatura*. Tese (Doutorado) — Universidade Federal Fluminense, 2015.

ANBAR, M. Computerized thermography. *International journal of technology assessment in health care*, Cambridge Univ Press, v. 3, n. 04, p. 613–621, 1987.

AMALU, W. C. Nondestructive testing of the human breast: the validity of dynamic stress testing in medical infrared breast imaging. In: IEEE. *Engineering in Medicine and Biology Society, 2004. IEMBS'04. 26th Annual International Conference of the IEEE*. [S.l.], 2004. v. 1, p. 1174–1177.

IBANEZ, L. et al. The itk software guide. 2003.

BROWN, L. G. A survey of image registration techniques. *ACM computing surveys (CSUR)*, ACM, v. 24, n. 4, p. 325–376, 1992.

CRUM, W. R.; HARTKENS, T.; HILL, D. Non-rigid image registration: theory and practice. *The British Journal of Radiology*, British Institute of Radiology, 2014.

PARRAGA, A. Atlas anatômico da região da cabeça e do pescoço: em direção à radioterapia adaptativa. 2008.

YIN, Y.; HOFFMAN, E. A.; LIN, C.-L. Mass preserving nonrigid registration of ct lung images using cubic b-spline. *Medical physics*, American Association of Physicists in Medicine, v. 36, n. 9, p. 4213–4222, 2009.

SCHWARZ, L. A. *Non-rigid registration using free-form deformations*. Tese (Doutorado) — Ph. D. thesis, Technische Universität München, Germany, 2007.

WHITLEY, D. A genetic algorithm tutorial. *Statistics and computing*, Springer, v. 4, n. 2, p. 65–85, 1994.

BURGES, C. et al. Learning to rank using gradient descent. In: ACM. *Proceedings of the 22nd international conference on Machine learning*. [S.l.], 2005. p. 89–96.

SHEPPARD, D.; TERRELL, R.; HENKELMAN, G. Optimization methods for finding minimum energy paths. *The Journal of chemical physics*, AIP Publishing, v. 128, n. 13, p. 134106, 2008.

HARALICK, R. M.; SHANMUGAM, K.; DINSTEN, I. H. Textural features for image classification. *Systems, Man and Cybernetics, IEEE Transactions on*, IEEE, n. 6, p. 610–621, 1973.

SEBASTIAN, V. et al. Gray level co-occurrence matrices: Generalisation and some new features. *arXiv preprint arXiv:1205.4831*, 2012.

ALBREGTSEN, F. et al. Statistical texture measures computed from gray level cooccurrence matrices. *Image processing laboratory, department of informatics, university of oslo*, p. 1–14, 2008.

HALL-BEYER, M. *The GLCM Tutorial Home Page*. 2008. <<http://www.fp.ucalgary.ca/mhallbey/tutorial.htm>>. Acessado em : 18/02/2016.

- HARALICK, R. M. Statistical and structural approaches to texture. *Proceedings of the IEEE*, IEEE, v. 67, n. 5, p. 786–804, 1979.
- CONNERS, R. W.; TRIVEDI, M. M.; HARLOW, C. A. Segmentation of a high-resolution urban scene using texture operators. *Computer Vision, Graphics, and Image Processing*, Elsevier, v. 25, n. 3, p. 273–310, 1984.
- FODOR, I. K. *A survey of dimension reduction techniques*. [S.l.]: Technical Report UCRL-ID-148494, Lawrence Livermore National Laboratory, 2002.
- JACKSON, J. E. *A user's guide to principal components*. [S.l.]: John Wiley & Sons, 2005. v. 587.
- RASCHKA, S. *Linear Discriminant Analysis bit a bit*. 2014. Disponível em: <http://sebastianraschka.com/Articles/2014_python_lda.html>. Acesso em: 22/02/2016.
- FISHER, R. A. The use of multiple measurements in taxonomic problems. *Annals of eugenics*, Wiley Online Library, v. 7, n. 2, p. 179–188, 1936.
- RAO, C. R. The utilization of multiple measurements in problems of biological classification. *Journal of the Royal Statistical Society. Series B (Methodological)*, JSTOR, v. 10, n. 2, p. 159–203, 1948.
- CORTES, C.; VAPNIK, V. Support vector machine. *Machine learning*, v. 20, n. 3, p. 273–297, 1995.
- LEARN scikit. *Support Vector Machines*. 2016. Disponível em: <<http://scikit-learn.org/stable/modules/svm.html>>. Acesso em: 23/02/2016.
- SILVA, G. L. F. da. Monografia, *Análise de Nódulos Pulmonares Usando Índices de Diversidade para estabelecer possíveis diferenças entre padrões malignos e benignos*. 2015. Monografia (Bacharel em Ciência da Computação), UFMA (Universidade Federal do Maranhão).
- CHAVES, A. d. C. F. *Extração de Regras Fuzzy para Máquinas de Vetores Suporte (SVM) para Classificação em Múltiplas Classes*. Tese (Doutorado) — PUC-Rio, 2006.
- HAYKIN, S. S. *Redes neurais*. [S.l.]: Bookman, 2001.
- MARQUES, R. Segmentação automática das mamas em imagens térmicas. *UFF, M. Sc. Thesis*, 2012.
- ABRÀMOFF, M. D.; MAGALHÃES, P. J.; RAM, S. J. Image processing with imagej. *Biophotonics international*, Laurin Publishing, v. 11, n. 7, p. 36–42, 2004.
- RASBAND, W.; IMAGEJ, U. et al. *Bethesda, Md, USA*. [S.l.]: ImageJ, 1997.