

1 Introdução

Lorem ipsum dolor sit amet, soleat oblique inciderint mei at. Mea harum legere delicata ut. Zril maiorum ea eum, affert adipiscing ad per, veniam nostro sit in. Nec ea falli oratio expetendis. Alii impetus prodesset mea ad, eum ei erroribus appellantur.

Eum etiam interpretaris ei, ad probo labores nam. Possit indoctum est no, nulla persius elaboraret sed ne. Vide summo pertinacia ea nec, et ius vocibus feugait. Dicat fuisset ex vix, dicta dolores pri et. Ex tempor petentium consulatu cum, dico eius dicat no est, ea cum liber virtute. Convenire posidonium mea in, pertinax scribentur eloquentiam eam ei, usu et labore dictas complectitur.

Ad sit eruditi dolorum, purto omittantur vix ut. Mel ad fugit adolescens, et nisl oblique molestiae pri, in incorrupte elaboraret vim. Vis erat praesent in, pri ad eros pertinax. Ex adhuc meliore delicatissimi cum, ut ius justo nulla, in ferri ceteros nam.

At mei quas admodum appellantur, cum ex dolores intellegam, sale soluta probatus ea eum. Rebum bonorum in pri, ad nam graeco insolens, ex esse facete has. Qui ei elit referrentur, eum alii scripta ne. Ei ius tantas mucius latine, justo percipitur cu ius, eum dicam mollis iisque eu. Nam dico tota splendide cu, pri an omittam dignissim voluptatum. Aequae tacimates consulatu eu usu, an pro pertinax electram.

Iudicabit corrumpit scribentur ad est, appareat vituperatoribus cu vix, case movet at quo. Dolorum maiestatis disputando no sit. At etiam dolorem usu, lorem summo quo an, pro dolore nusquam quaerendum eu. Eos suas mazim invenire et, accusam fabellas id nam, te eum doctus consequuntur. Conceptam elaboraret ad nec, est in etiam minimum fabella.

2 Objetivos

2.1 Objetivos Gerais

Desenvolver uma metodologia computacional que analise um exame termográfico dinâmico das mamas, a fim de encontrar padrões que diferenciem mamas saudáveis de mamas doentes.

A principal motivação do trabalho é ajudar médicos especialistas no diagnóstico precoce do câncer de mama, portanto qualquer informação que possa discriminar mamas saudáveis de mamas doentes é relevante.

2.2 Objetivos Específicos

Alguns objetivos extras são necessários para completar os objetivos gerais, sendo eles:

- Desenvolver técnicas que permitam a correção de postura em exames termográficos dinâmicos. Tais técnicas são conhecidas como registro de imagens, onde o resultado final pode variar muito de uma técnica utilizada para outra. Portanto, deve-se utilizar a que melhor se encaixe no problema.
- Analisar a variação de temperatura entre os diferentes tempos do exame, gerando características que sejam capazes de diferenciar os exames de pacientes saudáveis de exames de pacientes doentes.
- Utilizar as características extraídas para gerar um classificador automático, que seja capaz de classificar corretamente novos exames.

3 Fundamentação Teórica

Nesta seção, serão abordados os conceitos necessários para o entendimento da metodologia proposta.

3.1 A Termografia

A termografia é uma técnica que permite a visualização dos raios do espectro infravermelho de forma a mapear a temperatura de um objeto. A termografia infravermelha da mama é um tipo de exame que detecta a radiação infravermelha emitida pela superfície da mama produzindo um mapa de temperatura conhecido como termograma. A grande vantagem deste tipo de exame em relação aos exames mais conhecidos, como a mamografia, é que este não utiliza radiação no processo de obtenção das imagens e também não causa incômodo físico ao paciente, pois não é necessário a compressão das mamas, como ocorre na mamografia. Outro fator a se levar em consideração é o custo extremamente baixo e o fácil manuseio do equipamento necessário para obtenção do exame (BORCHARTT et al., 2013). A Figura 1 apresenta uma termografia em pseudocor, onde a temperatura varia de acordo com a paleta de cores à direita da imagem.




Figura 1 – Termografia mamária.

3.1.1 Termografia Estática

A termografia estática (TI), é o tipo de termografia onde a medição de temperatura é feita uma única vez. No caso de TI das mamas são procedimentos (SILVA et al., 2014) de preparação do ambiente e cuidados extras ao paciente para que o exame tenha resultado satisfatório, pois vários fatores podem influenciar o resultado final (SILVA, 2015).

3.1.2 Termografia Dinâmica

A termografia dinâmica (TID), é um tipo de termografia onde a medição de temperatura é realizada através de várias etapas de tempo, ou seja, TID mede as mudanças de temperatura sobre um determinado período de tempo. Originalmente conceituada por (ANBAR, 1987), onde notou-se que mudanças bruscas na temperatura da pele produziam informações valiosas, que não podem ser obtidos por meio de uma TI.

A TID apresenta uma característica importante na detecção de lesões mamárias, pois áreas saudáveis apresentam um comportamento distinto de áreas com algum tipo de patologia. Neoplásias são associadas com a angiogênese que causa um aumento de vascularização na região, sendo que, os vasos recém formados

apresentam a características de possuir poucas terminações nervosas, o que causa um comportamento irregular a estímulos externos, que é detectável através de um exame de termografia dinâmico (SILVA, 2015).

Na prática a TID monitora as mudanças na temperatura da pele, onde o estímulo térmico através de uma corrente de ar produz um contraste entre tecidos saudáveis e doentes. Regiões saudáveis da mama tendem a apresentar uma diminuição de temperatura com o estímulo de ar, enquanto as regiões doentes tendem a permanecer estáticas (AMALU, 2004).

3.2 Registro de Imagens

Quando imagens que foram extraídas de diferentes tempos, pontos de vista ou aparelhos precisam ser comparadas, ocorre um problema de alinhamento das coordenadas dessas imagens. É necessário efetuar alguma forma de processamento para que essas imagens possam ser comparadas adequadamente. O *Registro de Imagens* é uma técnica que utiliza uma transformação T para mapear a posição e o valor de intensidade de um pixel p da imagem A para q na imagem B , como pode ser visto pela Equação 3.1. Figura 2 mostra o efeito desse mapeamento.

$$T : p \rightarrow q \Leftrightarrow T(p) = q \quad (3.1)$$




Figura 2 – Registro de imagens é a tarefa de achar uma transformação espacial de uma imagem em outra.

Fonte: (IBANEZ et al., 2003)

Na literatura, é possível encontrar diversas definições para o problema de registro de imagens. De acordo com (BROWN, 1992), o processo de registro de imagens é transformação de conjuntos distintos de dados para um mesmo sistema de coordenadas. Em (CRUM; HARTKENS; HILL, 2014) é definido como um processo que determina correspondências entre as características de imagens extraídas em diferentes momentos, pontos de vista ou aparelhos. Tais correspondências podem ser utilizadas para aplicar transformações (rotação, translação, alongamento, etc.) em uma imagem de forma que seja possível a comparação entre as duas imagens. A forma mais intuitiva de utilização do registro é para corrigir diferenças na posição entre scans. Registro de imagens adiciona valor às imagens, permitindo que imagens estruturais (CT, MR, ultrassom) e funcionais (PET, SPECT, funcional MRI) sejam vistas e analisadas no mesmo sistema de coordenadas, e facilita o uso de novas imagens, como para monitorar e quantificar a evolução de uma doença à medida que o tempo passa (CRUM; HARTKENS; HILL, 2014).

A Figura 3 mostra o fluxograma básico de um processo de registro de imagens. O conjunto de entrada básico de um processo de registro de imagens é composto por:

- Imagem fixa: imagem estática cujo espaço de coordenadas é o objetivo.
- Imagem móvel: imagem que será transformada para o espaço de coordenadas da imagem fixa.
- Transformação: função que irá ser responsável por mapear os pixels da imagem móvel na imagem fixa.
- Métrica: uma medida que indica o quanto duas imagens são equivalentes.

- Interpolador: uma técnica para interpolar os valores da imagem móvel quando são reamostrados através da transformação.
- Otimizador: o método utilizado para achar os melhores parâmetros da transformação que otimizam a métrica entre as duas imagens.




Figura 3 – Fluxograma do processo de registro de imagens.

Fonte: (PARRAGA, 2008)

3.2.1 Métricas de similaridade

As métricas de similaridade são provavelmente o elemento mais crítico no problema do registro de imagens, pois define o objetivo final do processo que é medir o quanto a imagem móvel é equivalente à imagem fixa após a transformação ser aplicada. Existem métricas que podem ser utilizadas no processo do registro, entre elas temos a *Correlação Cruzada Normalizada* dada pela Equação 3.2

$$C(f, m) = -1 \cdot \frac{\sum_{i=1}^N (f_i \cdot m_i)}{\sqrt{\sum_{i=1}^N f_i^2 \cdot \sum_{i=1}^N m_i^2}} \quad (3.2)$$

onde, f e m são os valores de pixels em forma de vetor das imagens fixa e móvel, respectivamente, i indica a posição do pixel em f e m , N é a quantidade de pixels a ser considerado. Note que a equação é multiplicada por -1 . Esse fator é responsável por fazer o otimizador procurar os valores que mais se aproximem de 0, que é quando duas imagens são ditas equivalentes (IBANEZ et al., 2003).

3.2.2 Transformação

A transformação é responsável por mapear os pixels da imagem móvel para a imagem fixa. Podemos dividir as transformações em dois conjuntos distintos, rígidas e deformáveis.

As transformações rígidas aplicam sobre a imagem móvel apenas transformações simples como operações de translação e rotação, dessa forma a imagem móvel não sofre deformações, sofrendo apenas o alinhamento de suas coordenadas. Registros que utilizam transformações rígidas são chamados de registro rígidos e na prática não são utilizados individualmente, pois não são capazes de corrigir erros locais que necessitam de transformações mais complexas para serem resolvidas. Apesar disso, são bastante utilizados como pré-processamento para os chamados registros deformáveis.

As transformações deformáveis são capazes de efetuar deformações nas imagens, dessa forma é possível corrigir erros que uma transformação rígida não é capaz de corrigir. Registro de imagens que utilizam esse tipo de transformação são geralmente chamados de registros não-rígidos ou deformáveis. Um tipo de registro deformável muito utilizado atualmente é o *Registro Deformável B-Spline*, que utiliza *B-Splines* (BOOR et

al., 1978) de terceira ordem para gerar um conjunto de parâmetros para realizar o mapeamento da imagem móvel.

3.2.3 Interpolador

No processo do registro, a métrica geralmente compara os valores de intensidade dos pixels da imagem fixa com os pixels correspondentes na imagem móvel transformada. Quando transformamos um ponto de um espaço para o outro através de uma transformação, este geralmente irá ser mapeado para uma posição fora da grade de pixels da imagem. Dessa forma precisamos de interpolador para calcular o valor de pixel na posição mapeada. A Figura 4 (esquerda) mostra o mapeamento do espaço da imagem fixa na imagem móvel




Figura 4 – A imagem móvel é mapeada no espaço da imagem fixa a partir de uma transformação. Um iterador anda pela imagem fixa e as coordenadas são mapeada na imagem móvel.

Fonte: (IBANEZ et al., 2003)

3.2.4 Registro deformável *B-Spline*

3.3 Matrizes de Co-ocorrência de Níveis de Cinza

A análise de textura em imagens é uma técnica importante na identificação de características em imagens digitais. Uma das primeiras técnicas utilizadas para a extração dessas características foram as Matrizes de Co-ocorrências de níveis de cinza também chamadas de *GLCMs* (Gray Level Co-occurrence Matrix) originalmente propostas em (HARALICK; SHANMUGAM; DINSTEN, 1973). Desde então elas vem sendo bastante utilizadas em várias aplicações de análise de textura e permanecem sendo uma ferramenta importante no domínio de análise de texturas (SEBASTIAN et al., 2012).

A GLCM é uma técnica que utilizada para extrair características estatísticas de textura de segunda ordem (ALBREGTSEN et al., 2008), ou seja, a medição considera a relação entre pares de pixels, geralmente vizinhos (HALL-BEYER,).

3.3.1 Construção de uma GLCM

Seja I uma imagem em níveis de cinza e N a quantidade de níveis de cinza, uma matriz de co-ocorrência G é uma matriz quadrada de ordem N (SEBASTIAN et al., 2012). O elemento da matriz $P(i, j | \Delta x, \Delta y)$ é a frequência relativa em que dois pixels de intensidade (i, j) , separados por uma distância $(\Delta x, \Delta y)$, são vizinhos. Também é possível dizer que o elemento $P(i, j | d, \theta)$ contém os valores da probabilidade de segunda

ordem para mudanças entre os níveis de cinza i e j em uma distância d e um ângulo θ (ALBREGTSEN et al., 2008).

Seja I uma imagem de dimensões $W \times H$, então uma GLCM de ir pode ser definida pela Equação 3.3.

$$G(i, j | \Delta x, \Delta y) = \sum_{p=1}^W \sum_{q=1}^H A \quad (3.3)$$

$$A = \begin{cases} 1, & \text{se } I(p, q) = i \text{ e } I(p + \Delta x, q + \Delta y) = j \\ 0, & \text{caso contrário} \end{cases} \quad (3.4)$$

Como exemplo temos uma imagem I de dimensões 5×5 , com 4 níveis de cinza. Então as matrizes de co-ocorrência $G(i, j | \Delta x = 1, \Delta y = 0)$ e $G(i, j | \Delta x = 1, \Delta y = 1)$ são representadas abaixo.

$$I = \begin{bmatrix} 2 & 0 & 2 & 1 & 1 \\ 2 & 1 & 2 & 3 & 1 \\ 3 & 1 & 3 & 2 & 0 \\ 0 & 0 & 1 & 2 & 2 \\ 3 & 3 & 3 & 1 & 1 \end{bmatrix}$$

$$G(i, j | \Delta x = 1, \Delta y = 0) = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 2 & 2 & 1 \\ 2 & 2 & 1 & 1 \\ 0 & 3 & 1 & 2 \end{bmatrix}$$

$$G(i, j | \Delta x = 1, \Delta y = 1) = \begin{bmatrix} 0 & 0 & 1 & 2 \\ 0 & 3 & 0 & 1 \\ 0 & 3 & 2 & 1 \\ 2 & 0 & 1 & 0 \end{bmatrix}$$

3.3.2 GLCM Normalizada

Considere $N = \sum_i \sum_j G_d(i, j)$, que é a quantidade co-ocorrências de pares em G_d . Seja $GN_d(i, j) = \frac{1}{N} G_d(i, j) \cdot GN_d$, chamada de matriz de co-ocorrência normalizada, onde as entradas (i, j) de $GN_d(i, j)$ são as probabilidades de co-ocorrência de um determinado pixel com intensidade i ser separado de um pixel de intensidade j por uma distância k em uma determinada direção d (SEBASTIAN et al., 2012).

3.3.3 Características de Textura

A partir de uma GLCM, é possível extrair um conjunto de características que descrevem a textura de determinada imagem (ALBREGTSEN et al., 2008), disponíveis em (HARALICK; SHANMUGAM; DINSTEIN, 1973; HARALICK, 1979; CONNERS; TRIVEDI; HARLOW, 1984). De acordo com (HALL-BEYER,) temos as seguintes características que podem ser extraídas a partir de uma GLCM:

$$Contraste = \sum_{i,j=0}^{N-1} P_{i,j} (i - j)^2 \quad (3.5)$$

$$Dissimilaridade = \sum_{i,j=0}^{N-1} P_{i,j} |i - j| \quad (3.6)$$

$$Homogeneidade = \sum_{i,j=0}^{N-1} \frac{P_{i,j}}{1 + (i - j)^2} \quad (3.7)$$

$$ASM = \sum_{i,j=0}^{N-1} P_{i,j}^2 \quad (3.8)$$

$$Energia = \sqrt{ASM} \quad (3.9)$$

$$Correlação = \sum_{i,j=0}^{N-1} P_{i,j} \left[\frac{(i - \mu_i) \cdot (j - \mu_j)}{\sqrt{(\sigma_i^2) \cdot (\sigma_j^2)}} \right] \quad (3.10)$$

$$\mu_i = \sum_{i,j=0}^{N-1} i \cdot (P_{i,j}) \quad (3.11)$$

$$\mu_j = \sum_{i,j=0}^{N-1} j \cdot (P_{i,j}) \quad (3.12)$$

$$\sigma_i^2 = \sum_{i,j=0}^{N-1} P_{i,j} (i - \mu_i)^2 \quad (3.13)$$

$$\sigma_j^2 = \sum_{i,j=0}^{N-1} P_{i,j} (j - \mu_j)^2 \quad (3.14)$$

onde N é quantidade de níveis de cinza $P_{i,j}$ é a frequência de um par de pixels i e j serem vizinhos.

3.4 Redução de Dimensionalidade

Em *Aprendizado de Máquina*, geralmente possuímos um conjunto de dados previamente disponíveis para utilizar em um classificador qualquer. Nesse conjunto de dados, cada indivíduo é representado por um conjunto de características extraídas do dado original. Por exemplo, em imagens de níveis de cinza é possível extrair as características representadas pelas Equações 3.5,3.6,3.7,3.8,3.9e3.10 a partir de um GLCM qualquer. A quantidade de características que um indivíduo possui é o que chamamos de *dimensão*. Para um conjunto de dados de dimensão $D = 6$, então temos 6 características que descrevem cada indivíduo.

A fácil pensar que quanto maior o número de características, melhor para discriminar os indivíduos. Porém, um conjunto de dados com uma dimensão muito alta implica maior complexidade no problema de classificação. Outro problema é que, em muitos casos, nem todas as características são consideradas importantes para o entendimento de um certo problema(FODOR, 2002).

Em termos matemáticos, o problema de *Redução de Dimensionalidade* pode ser descrito da seguinte forma: Dado um conjunto dados com p dimensões $x = (x_1, x_2, \dots, x_p)^T$, encontrar uma representação de menor dimensão $s = (s_1, s_2, \dots, s_k)^T$, onde $k \leq p$, que seja capaz de capturar o conteúdo dos dados originais, de acordo com um critério pré-estabelecido (FODOR, 2002).

Algumas técnicas de redução de dimensionalidade são descritas abaixo.

3.4.1 Seleção de características univariada

A seleção de características univariada seleciona as melhores características baseada em testes estatísticos univariados (LEARN,). Por exemplo, podemos selecionar as K melhores características através de um teste estatístico que classifique as características que melhor separam as classes de indivíduos de um conjunto de dados.

3.4.2 Principal Component Analysis

O *Principal Component Analysis* (PCA) é uma técnica de redução linear (JACKSON, 2005). Por ser baseada na matriz de covariância dos dados, é um método de segunda ordem. O PCA reduz a dimensionalidade encontrando os *principais componentes* (PCs) do conjunto de dados com maior variância, que são vetores formados pelas combinações das características originais. Por exemplo, o primeiro PC é o que possui maior variância, Temos $s_1 = x^T w_1$, onde o vetor de coeficientes de p dimensões é $w_1 = (w_{1,1}, \dots, w_{1,p})^T$ que resolve:

$$w_1 = \arg \max_{\|w=1\|} \text{Var}\{x^T w\} \quad (3.15)$$

O segundo PC é a combinação linear com a segunda maior variância e ortogonal ao primeiro PC, e assim sucessivamente. Existem tantos PCs quanto o número de características originais (FODOR, 2002).

Geralmente, normaliza-se os dados antes da aplicação do PCA, pois o método é dependente da escala. Um dos métodos possíveis para a normalização é escalar cada características entre 0 e 1. Então, assumindo que os dados estão normalizados, podemos calcular a matriz de covariância

$$C = \frac{1}{p-1} \sum_{i=1}^p (x_i - \bar{x}) \cdot (x_i - \bar{x})^T, \quad (3.16)$$

onde \bar{x} é o vetor médio dado por

$$\bar{x} = \frac{1}{p} \sum_{i=1}^p x_i \quad (3.17)$$

Utilizando a relação dos autovetores e autovalores

$$Cv = \lambda v, \quad (3.18)$$

onde v é um autovetor de C e λ o seu respectivo autovalor. Cada autovetor corresponde a um PC, e os respectivos autovalores indicam o grau de variância de cada PC. Assim, escolhendo os k PCs com maior variância absoluta, podemos mapear nossos dados originais em um novo conjunto

$$S = W^T X, \quad (3.19)$$

onde X é o conjunto de dados originais e W uma matriz de transformação

$$W = (v_1, \dots, v_k), \quad (3.20)$$

onde v_1 é o PC de maior variância e v_k o k -ésimo PC de maior variância.

É uma técnica muito útil quando queremos transformar nossas características originais, onde algumas delas não oferecem muita variação nos dados, em um espaço novo com menor dimensão onde as novas características possuem uma melhor dispersão nos dados. A Figura 5 mostra um conjunto de indivíduos

gerados por distribuições normais multivariadas com 3 características. Utilizando o PCA para reduzir o espaço dimensional para apenas 2, temos a Figura 6, que exemplifica o efeito da redução.




Figura 5 – Amostras geradas utilizando um distribuição normal multivariada.

Fonte: Elaborada pelo autor




Figura 6 – Amostras reduzidas para o espaço bidimensional utilizando os dois principais componentes.

Fonte: Elaborada pelo autor

3.4.3 Linear Discriminant Analysis

Linear Discriminant Analysis (LDA) é uma técnica similar ao PCA, onde buscamos combinações lineares das características para formar um novo espaço de dimensões reduzidas. A diferença é que ao contrário do PCA que busca combinações com maior variância entre os dados, o LDA procura combinações que melhor separam as classes de um determinado problema, portanto podemos dizer que o LDA é uma técnica supervisionada, pois precisamos conhecer as classes que cada indivíduo pertence.

Normalmente é utilizado para redução de dimensionalidade, como um pré-processamento de técnicas de aprendizado de máquina e reconhecimento de padrões (RASCHKA,). Também é possível utilizar o LDA




Figura 7 – Distância intra-classe.

Fonte: Elaborada pelo autor

como um classificador. Originalmente proposto em (FISHER, 1936) como um problema de *2-class*, que foi generalizado para um problema *multi-class* em (RAO, 1948).

Considerando um conjunto de observações X de dimensões $k \times p$, em que k corresponde à quantidade de indivíduos e p à quantidade de características de cada indivíduo. Para cada indivíduo em X , existe um elemento em y que indica a classe ao qual pertence. O objetivo é encontrar uma transformação W , que maximize a distância entre classes (Figura 8) e minimize a distância intra-classe (Figura 7).




Figura 8 – Distância entre-classes.

Fonte: Elaborada pelo autor

Dessa forma W mapeia X em \bar{X} através da Equação 3.21

$$\bar{X} = W^T \cdot X \quad (3.21)$$

onde W é formado pelos m autovetores com maiores autovalores absolutos da matriz S dada pela Equação 3.22. Uma observação importante é que $m < c - 1$, onde c é a quantidade de classes que existem em y (RASCHKA,).

$$S = S_W^{-1} \cdot S_B \quad (3.22)$$

A matriz S_W é o que chamamos de matriz de dispersão intra-classe e é definida por:

$$S_W = \sum_{i=1}^c S_i \quad (3.23)$$

$$S_i = \sum_{x \in c_i}^n (x - \mu_i) \cdot (x - \mu_i)^T \quad (3.24)$$

$$\mu_i = \frac{1}{n_i} \sum_{x \in c_i}^n x_k \quad (3.25)$$

onde, S_i é matriz de dispersão da classe c_i e μ_i é o vetor que representa os valores médios de cada característica de indivíduos que pertecem a classe c_i .

A matriz S_B é chamada de matriz de dispersão entre-classes e é definida por:

$$S_B = \sum_{i=1}^c N_i (\mu_i - \mu) \cdot (\mu_i - \mu)^T \quad (3.26)$$

onde, N_i é a quantidade de indivíduos que pertecem a classe c_i e μ é o vetor que representa a média das características de todos os indivíduos em X .

A vantagem de utilizar o LDA é que simplificamos o problema de classificação criando novas características, a partir das originais, que melhor separam as classes do conjunto de dados. A grande desvantagem é que não é possível saber quais características originais tem maior peso, pois os discriminantes são formados a partir de combinações lineares de todas elas. A Figura 9 apresenta um conjunto de indivíduos que pertecem a três classes distintas. Cada classe foi gerada a partir de uma distribuição normal multivariada, onde os parâmetros diferem entre elas. A Figura 10 apresenta o resultado da aplicação do LDA para efetuar a redução do espaço tridimensional para bidimensional.




Figura 9 – Amostras geradas de distribuições normais multivariadas.

Fonte: Elaborada pelo autor




Figura 10 – Resultado da aplicação do LDA para reduzir as amostras da Figura 9.

Fonte: Elaborada pelo autor

3.5 *Support Vector Machines*

Problemas de classificação geralmente envolvem classificar se um certo indivíduo pertence à classe A, B ou C . Atualmente existem diversas técnicas de aprendizado de máquina capazes de realizar essa tarefa com êxito e umas das principais técnicas utilizadas hoje em dia são as *Support Vector Machines* (SVM). Foram originalmente propostas por (CORTES; VAPNIK, 1995) como um classificador binário, capaz de dizer se um determinado indivíduo pertence à classe A ou B . São parte do grupo de técnicas de aprendizado supervisionado, onde é necessário conhecer previamente um conjunto de indivíduos para que o algoritmo gere um modelo que seja capaz de prever qual a classe uma nova entrada pertence.

Uma SVM constrói hiperplanos em um espaço de alta dimensão, que pode ser utilizado para a tarefa de classificação. Uma boa separação é obtida através do hiperplano que possui maior distância entre os pontos mais próximos de cada classe no conjunto de dados de treino (LEARN,).




Figura 11 – Construção de hiperplanos.

Fonte: (LEARN,)

De acordo com (SILVA, 2015), dado (x_k, y_k) o conjunto de amostras para treinamento, sendo que $x_i \in \mathbb{R}^n$ correspondente ao vetor de características do indivíduo i , $y_i \in \{1, -1\}$ corresponde à classe do indivíduo i , sendo $i = 1, 2, \dots, k$. O objetivo do problema de classificação é encontrar uma função $f(x) : \mathbb{R}^n \rightarrow \{1, -1\}$ que seja capaz de estimar corretamente a classe do indivíduo x .

Na etapa de treinamento a função $f(x) = (w \cdot x) + b$ é estimada, de forma que a seguinte relação seja satisfeita:

$$y_i((w \cdot x_i) + b) \geq 1 \quad (3.27)$$

onde w é o vetor normal ao hiperplano e b a distância da função f em relação à origem. Os valores ótimos de w e b são encontrados de acordo com a restrição dada pela Equação 3.27 ao minimizar a equação:

$$\phi(w) = \frac{w^2}{2} \quad (3.28)$$

O SVM possibilita encontrar um hiperplano que minimize a ocorrência de erros nos casos em que a separação ótima entre as classes não seja possível. Com o advento de variáveis de folga, é possível relaxar a restrição da Equação 3.27. Dessa forma o SVM resolve problema de otimização:

$$\min \phi(w, \zeta) = \frac{w^2}{2} C \sum_{i=1}^N \zeta_i \quad (3.29)$$

sujeito à:

$$y_i((w \cdot x_i) + b) + \zeta_i \geq 1 \quad (3.30)$$

onde C é um parâmetro de treinamento que define o equilíbrio entre a complexidade do modelo e o erro de treinamento.




Figura 12 – Vetores de suporte.

Fonte: Elaborada pelo autor

Utilizando a teoria dos multiplicadores de Lagrange é possível obter:

$$L(a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i,j=1}^N a_i a_j y_i y_j (x_i, x_j) \quad (3.31)$$

Assim, o objetivo passa a ser encontrar os multiplicadores de Lagrange a_i ótimos que satisfaçam a Equação 3.32 (CHAVES, 2006).

$$\sum_{i=1}^N a_i y_i = 0, \quad 0 \leq a_i \leq C \quad (3.32)$$

Apenas os pontos onde a restrição imposta pela Equação 3.27 é igual 1, tem correspondentes $a_i \neq 0$. Esses pontos são chamados de vetores de suporte, e estão geometricamente sobre as margens, possuindo grande importância na definição do hiperplano ótimo, pois delimitam as margens do conjunto de treinamento. Na Figura 12, os vetores de suporte são representados por círculos circunscritos.

Pontos além da margem não tem influência suficiente para determinar o hiperplano, porém esses vetores de suporte são essenciais nessa tarefa.

Agora considere o conjunto de amostras da Figura 13. Vemos que não é possível traçar uma reta capaz de separar as classes, tornando o problema um caso não-linear. De acordo com (SILVA, 2015), precisamos de uma transformação não-linear capaz de mapear o conjunto original (espaço dados) para um novo espaço (espaço de características). Esse novo espaço deve apresentar dimensões suficientes para que seja possível realizar a separação linear do conjunto de dados. Dessa forma, o hiperplano de separação é definido como uma função linear de vetores retirados do espaço de características e não do espaço de dados. A construção desse conjunto depende de uma função K , chamada de *kernel* (HAYKIN, 2001). A Equação 3.33 apresenta a forma modificada da 3.32 utilizando uma função K .




Figura 13 – Conjunto de indivíduos não separáveis linearmente.

Fonte: Elaborada pelo autor

$$L(a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i,j=1}^N a_i a_j y_i y_j K(x_i, x_j) \quad (3.33)$$

Um conjunto de funções amplamente utilizadas em conjunto com o SVM para classificação de dados não linearmente separáveis são as funções de base radial (RBF). Uma função RBF é definida por:

$$K(x_i, y_i) = \exp(-\gamma \|x_i - y_i\|^2) \quad (3.34)$$

onde $\gamma = 1/\sigma^2$, onde σ é a variância.

4 Metodologia

Nesta seção, são apresentados os procedimentos propostos para a realização dos objetivos descritos na Seção 2. A Figura 14 apresenta o fluxo das etapas executadas.




Figura 14 – Fluxograma da metodologia.

Fonte: Elaborada pelo autor

4.1 Aquisição de Imagens

A aquisição de imagens é uma etapa crucial na metodologia proposta, pois sem imagens para casos de teste não é possível validar a metodologia. Atualmente existem poucos bancos de imagem termografias mamárias disponíveis para o público geral, sendo a maioria deles de propósito privado. As imagens utilizadas neste trabalho são provenientes do *Database for Mastology Research with Infrared Image* - DMR-IR, acessível através da interface on-line <<http://visual.ic.uff.br/dmi>>. Mais informações sobre a base de imagens utilizada podem ser encontradas em (SILVA et al.,) e (SILVA et al., 2014).

De acordo com (SILVA et al., 2014), no protocolo de termografias dinâmicas as pacientes são submetidas à um estresse térmico causado pela refrigeração por um ventilador elétrico. Quando a média de temperatura entre as mamas é de 30.5°C (Figura 15), ou 5 minutos de estresse foram aplicados, a refrigeração é interrompida e a aquisição sequencial das imagens é iniciada, extraíndo um total de 20 imagens sequenciais com intervalos de tempo fixos.


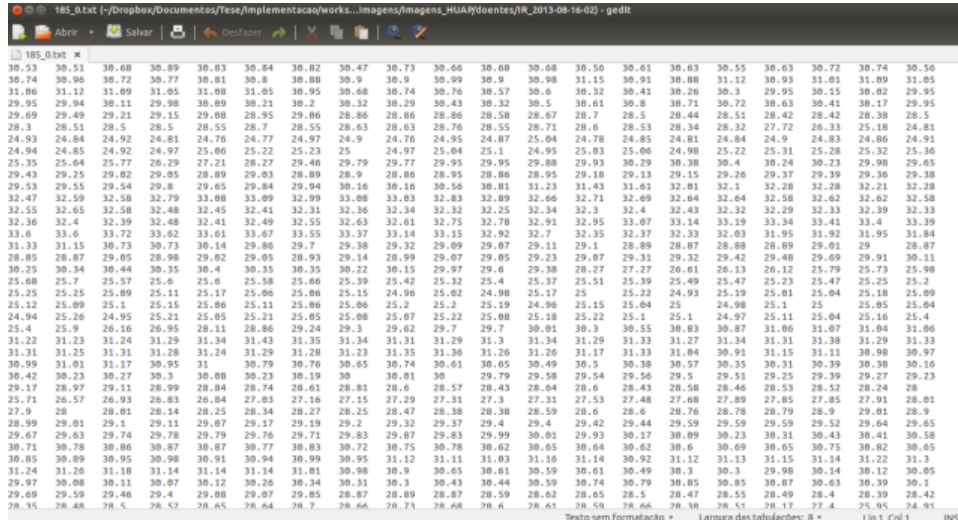


Figura 15 – Monitoramento da temperatura média para começar a aquisição sequencial.

Fonte: (SILVA et al., 2014)

As imagens utilizadas possuem dimensão de 640 pixels de largura e 480 pixels de altura e foram utilizados os valores de temperatura (em graus celsius) obtidos diretamente da câmera termográfica utilizada na aquisição. A Figura 16 apresenta essas matrizes são armazenadas em formato *.txt*, onde cada exame é composto por 20 arquivos separados por tempo de aquisição.



The image shows a screenshot of a text editor window titled '185_0.txt'. The window displays a large grid of numerical values, representing temperature data. The values are organized in rows and columns, with some cells containing multiple values separated by spaces. The editor's interface includes a menu bar with options like 'Arquivo', 'Editar', 'Formatar', 'Ferramentas', 'Janela', and 'Ajuda'. The status bar at the bottom indicates 'Tamanho: 10.000 bytes', 'Linhas: 100', 'Colunas: 100', and 'Página: 1 de 1'.

Figura 16 – Matriz de temperatura.

Fonte: (SILVA, 2015)

No total foram utilizados 70 exames previamente diagnosticados para aplicação desta metodologia, sendo que 35 são de pacientes saudáveis e os 35 restantes de pacientes que apresentam algum tipo de anomalia nas mamas.

4.2 Extração da Região de Interesse

Essa etapa consiste em extrair a região de interesse (ROI) da imagem. Como a metodologia tem o objetivo de detectar anomalias no padrão de vascularização das mamas, é de interesse que as demais regiões de uma TID sejam excluídas do processo. Alguns métodos de segmentação automática são encontrados na literatura (MARQUES, 2012), porém existem limitações que não tornam possíveis a utilização desse tipo de técnica. Dessa forma, a região de interesse é extraída de forma manual, através da utilização de um programa de visualização e extração de imagens.

Apesar de cada TID possuir um total de 20 sequências de termogramas, utilizamos apenas a sequência no tempo inicial para gerar uma máscara responsável por demarcar a ROI segmentada manualmente através do software ImageJ (ABRAMOFF; MAGALHÃES; RAM, 2004; RASBAND; IMAGEJ et al., 1997). Utilizando a máscara da sequência inicial é possível extrair as ROIs das demais sequências após a aplicação do registro dos termogramas (Seção 4.3). A Figura 17a demonstra a etapa de segmentação manual utilizando o mouse para desenhar o polígono que definirá a ROI. Como resultado uma máscara binária (Figura 17b) é gerada, para ser utilizada como ROI para todos as 20 sequências de termogramas em um exame.




Figura 17 – Extração da região das mamas através do software ImageJ.

Fonte: (SILVA, 2015)

4.3 Registro das Imagens

Durante o protocolo de aquisição de imagens, é natural que a paciente execute movimentos involuntários causados pela respiração e ajuste de postura. Esses movimentos causam diferenças espaciais de uma sequência para a outra. As Figuras 18a e 18b são termogramas sequenciais de tempos $t = 1$ e $t = 2$, respectivamente. A Figura 18c apresenta a diferença quadrática $d = (P_t(i, j) - P_t(i, j))$, onde (i, j) é a posição do pixels, sendo $i = 0, \dots, 639$ e $j = 0, \dots, 479$, e $P_t(i, j)$ é o valor de pixel na posição (i, j) no tempo t . É possível notar que existe uma diferença causada pela movimentação involutária da paciente.




Figura 18 – Termogramas dos sequenciais e a diferença de postura entre eles

Fonte: Elaborada pelo autor.

Para analisar as sequências de termogramas de um determinado exame é necessário corrigir essas diferenças, dessa forma o registro *B-Spline* apresentado na Seção 3.2.4 é utilizado. Como dito anteriormente, o registro é uma técnica de projeção de uma imagem no espaço de coordenadas de outra, ou seja, ideal para o problema de correção de postura. Utilizando o primeiro termograma da sequência de um exame como imagem fixa e os termogramas restantes como imagem móvel, executamos o registro para um determinado exame 19 vezes, uma para cada imagem móvel. O registro utiliza a Correlação (Equação X) como métrica de similaridade. O

Referências

- BORCHARTT, T. B. et al. Breast thermography from an image processing viewpoint: A survey. *Signal Processing*, Elsevier, v. 93, n. 10, p. 2785–2803, 2013.
- SILVA, L. et al. A new database for breast research with infrared image. *Journal of Medical Imaging and Health Informatics*, American Scientific Publishers, v. 4, n. 1, p. 92–100, 2014.
- SILVA, L. F. D. *Uma Análise Híbrida para Detecção de Anomalias da Mama usando Séries Temporais de Temperatura*. Tese (Doutorado) — Universidade Federal Fluminense, 2015.
- ANBAR, M. Computerized thermography. *International journal of technology assessment in health care*, Cambridge Univ Press, v. 3, n. 04, p. 613–621, 1987.
- AMALU, W. C. Nondestructive testing of the human breast: the validity of dynamic stress testing in medical infrared breast imaging. In: IEEE. *Engineering in Medicine and Biology Society, 2004. IEMBS'04. 26th Annual International Conference of the IEEE*. [S.l.], 2004. v. 1, p. 1174–1177.
- IBANEZ, L. et al. The itk software guide. 2003.
- BROWN, L. G. A survey of image registration techniques. *ACM computing surveys (CSUR)*, ACM, v. 24, n. 4, p. 325–376, 1992.
- CRUM, W. R.; HARTKENS, T.; HILL, D. Non-rigid image registration: theory and practice. *The British Journal of Radiology*, British Institute of Radiology, 2014.
- PARRAGA, A. Atlas anatômico da região da cabeça e do pescoço: em direção à radioterapia adaptativa. 2008.
- BOOR, C. D. et al. *A practical guide to splines*. [S.l.]: Springer-Verlag New York, 1978. v. 27.
- HARALICK, R. M.; SHANMUGAM, K.; DINSTEN, I. H. Textural features for image classification. *Systems, Man and Cybernetics, IEEE Transactions on*, Ieee, n. 6, p. 610–621, 1973.
- SEBASTIAN, V. et al. Gray level co-occurrence matrices: Generalisation and some new features. *arXiv preprint arXiv:1205.4831*, 2012.
- ALBREGTSEN, F. et al. Statistical texture measures computed from gray level cooccurrence matrices. *Image processing laboratory, department of informatics, university of oslo*, p. 1–14, 2008.
- HALL-BEYER, M. *The GLCM Tutorial Home Page*. <<http://www.fp.ucalgary.ca/mhallbey/tutorial.htm>>. Acessado em : 18/02/2016.
- HARALICK, R. M. Statistical and structural approaches to texture. *Proceedings of the IEEE*, IEEE, v. 67, n. 5, p. 786–804, 1979.
- CONNERS, R. W.; TRIVEDI, M. M.; HARLOW, C. A. Segmentation of a high-resolution urban scene using texture operators. *Computer Vision, Graphics, and Image Processing*, Elsevier, v. 25, n. 3, p. 273–310, 1984.
- FODOR, I. K. *A survey of dimension reduction techniques*. [S.l.]: Technical Report UCRL-ID-148494, Lawrence Livermore National Laboratory, 2002.
- LEARN scikit. *Feature Selection*. Disponível em: <http://scikit-learn.org/stable/modules/feature_selection.html>. Acesso em: 20/02/2016.
- JACKSON, J. E. *A user's guide to principal components*. [S.l.]: John Wiley & Sons, 2005. v. 587.

RASCHKA, S. *Linear Discriminant Analysis bit a bit*. Disponível em: <http://sebastianraschka.com/Articles/2014_python_lda.html>. Acesso em: 22/02/2016.

FISHER, R. A. The use of multiple measurements in taxonomic problems. *Annals of eugenics*, Wiley Online Library, v. 7, n. 2, p. 179–188, 1936.

RAO, C. R. The utilization of multiple measurements in problems of biological classification. *Journal of the Royal Statistical Society. Series B (Methodological)*, JSTOR, v. 10, n. 2, p. 159–203, 1948.

CORTES, C.; VAPNIK, V. Support vector machine. *Machine learning*, v. 20, n. 3, p. 273–297, 1995.

LEARN scikit. *Support Vector Machines*. Disponível em: <<http://scikit-learn.org/stable/modules/svm.html>>. Acesso em: 23/02/2016.

SILVA, G. L. F. da. Monografia, *Análise de Nódulos Pulmonares Usando Índices de Diversidade para estabelecer possíveis diferenças entre padrões malignos e benignos*. 2015. Monografia (Bacharel em Ciência da Computação), UFMA (Universidade Federal do Maranhão).

CHAVES, A. d. C. F. *Extração de Regras Fuzzy para Máquinas de Vetores Suporte (SVM) para Classificação em Múltiplas Classes*. Tese (Doutorado) — PUC-Rio, 2006.

HAYKIN, S. S. *Redes neurais*. [S.l.]: Bookman, 2001.

SILVA, L. et al. Asmd, and conci, a.(2013). *Protocolo de captura de imagens térmicas da mama para construção de um banco público de exames*. Encontro Nacional de Engenharia Biomecânica.

MARQUES, R. Segmentação automática das mamas em imagens térmicas. *UFF, M. Sc. Thesis*, 2012.

ABRÀMOFF, M. D.; MAGALHÃES, P. J.; RAM, S. J. Image processing with imagej. *Biophotonics international*, Laurin Publishing, v. 11, n. 7, p. 36–42, 2004.

RASBAND, W.; IMAGEJ, U. et al. *Bethesda, Md, USA*. [S.l.]: ImageJ, 1997.