

UNIVERSIDADE FEDERAL DO MARANHÃO

CENTRO DE CIÊNCIAS EXATAS E TECNOLÓGICAS

DEPARTAMENTO DE INFORMÁTICA

CURSO DE CIÊNCIA DA COMPUTAÇÃO

PROJETO DE MONOGRAFIA

Análise e Classificação de Termografias Dinâmicas das Mamas Utilizando a Variação de Temperatura e Máquinas de Vetor de Suporte

São Luís

2016

Caio Nogueira Silva Belfort

Aluno do Curso de Ciência da Computação

Prof. Dr. Aristóфанes Córrea Silva

Orientador

Prof. Msc. Carlos Eduardo Portela Serra de Castro

Coordenador do Curso de Ciência da Computação

Resumo

A termografia das mamas é um exame de imagem que utiliza a radiação infravermelha naturalmente emitida pelo corpo da paciente para detecção de anomalias. Possui a capacidade de detectar o câncer de mama mais precocemente que a mamografia, sem causar nenhum efeito colateral ou incômodo físico na paciente. O processamento de imagens médicas é uma área que vem ganhando destaque recentemente, pois metodologias de diagnóstico automático podem auxiliar médicos especialistas na detecção de doenças de forma precoce, aumentando as chances de cura. Este trabalho apresenta uma metodologia de processamento e análise de termografias dinâmicas da mama, como forma de auxiliar médicos especialista no diagnóstico de doenças relacionadas ao tecido mamário. O registro de imagens é utilizado para efetuar a correção do erro de postura entre os diversos tempos de uma termografia dinâmica. Valores estatísticos são utilizados para medir a variação de temperatura entre os pixels, formando novas imagens a partir da termografia original. Em seguida a extração de características de textura é efetuada em cada imagem estatística, formando um conjunto de valores conhecido como vetor de características. O vetor de característica é reduzido através de técnicas de redução de características para posteriormente servir de entrada para uma máquina de vetor de suporte que irá efetuar a classificação em exame saudável ou exame com algum tipo de anomalia. A metodologia apresenta 82,5% de acurácia, 84,1 % de sensibilidade e 81,0% de especificidade.

Palavras chave: Câncer, Mama, Termografia, Aprendizado de Máquina

Lista de ilustrações

Figura 1 – Termografia mamária.	11
Figura 2 – Registro de imagens é a tarefa de achar uma transformação espacial de uma imagem em outra.	12
Figura 3 – Fluxograma do processo de registro de imagens.	13
Figura 4 – Efeito da translação.	14
Figura 5 – Rotação de $\theta = \frac{\pi}{2} = 90^\circ$	15
Figura 6 – Transformação de escala.	15
Figura 7 – O conceito de campo de deslocamento. Para cada posição de pixel na imagem móvel, existe uma direção e distância que ele precisa se mover para se assemelhar à imagem fixa.	16
Figura 8 – Posições de grade da imagem fixa mapeadas para posições fora da grade na imagem móvel.	17
Figura 9 – Amostras geradas utilizando uma distribuição normal multivariada.	22
Figura 10 – Amostras reduzidas para o espaço bidimensional utilizando os dois principais componentes.	22
Figura 11 – Distância intra-classe.	23
Figura 12 – Distância inter-classes.	23
Figura 13 – Amostras geradas de distribuições normais multivariadas.	24
Figura 14 – Resultado da aplicação do LDA para reduzir as amostras da Figura 13.	24
Figura 15 – Construção de hiperplanos.	25
Figura 16 – Vetores de suporte.	26
Figura 17 – Conjunto de indivíduos não separáveis linearmente.	27
Figura 18 – Fluxograma da metodologia.	28
Figura 19 – Monitoramento da temperatura média para começar a aquisição sequencial.	28
Figura 20 – Matriz de temperatura.	29
Figura 21 – Termogramas de tempos distintos. Tons mais claros denotam uma maior diferença entre as regiões.	29
Figura 22 – Resultado da aplicação do registro na Figura 21b como móvel e a Figura 21a como fixa. Note que a diferença de postura foi corrigida, deixando a imagem majoritariamente escura.	30
Figura 23 – Extração da região das mamas através do software ImageJ.	31
Figura 24 – Temperatura Inicial. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante. Note a assimetria existente em (b).	32
Figura 25 – Ganho de temperatura total. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante. A região mais avermelhada em (b) coincide com a região em que o tumor aparece.	32
Figura 26 – Ganho de temperatura média entre os tempos da TID. Em (a) vemos um exame de paciente saudável, enquanto em (b) temos uma paciente com lesão na mama.	33
Figura 27 – Desvio padrão do ganho de temperatura em uma TID. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com lesão.	33

Lista de tabelas

Tabela 1 – Média final da execução dos testes 100 vezes para cada método de seleção de características.	35
Tabela 2 – Cronograma do plano de trabalho.	36

Sumário

1	INTRODUÇÃO	8
2	OBJETIVOS	10
2.1	Objetivos Gerais	10
2.2	Objetivos Específicos	10
3	FUNDAMENTAÇÃO TEÓRICA	11
3.1	A Termografia	11
3.1.1	Termografia Estática	11
3.1.2	Termografia Dinâmica	11
3.2	Registro de Imagens	12
3.2.1	Métricas de similaridade	13
3.2.1.1	Correlação Cruzada Normalizada	13
3.2.2	Transformação	13
3.2.2.1	Translação	14
3.2.2.2	Rotação	14
3.2.2.3	Escala	15
3.2.2.4	Transformações FFD baseadas em <i>B-Splines</i> cúbicas	15
3.2.3	Interpolador	17
3.2.3.1	Interpolador Linear	17
3.2.4	Otimizador	17
3.2.4.1	LBFGS	17
3.3	Matrizes de Coocorrência de Níveis de Cinza	18
3.3.1	Construção de uma GLCM	18
3.3.2	GLCM Normalizada	19
3.3.3	Características de Textura	19
3.4	Redução de Dimensionalidade	20
3.4.1	Seleção de Características Univariada	20
3.4.2	Análise de Componentes Principais	21
3.4.3	Análise Discriminante Linear	22
3.5	Máquinas de Vetor de Suporte	25
4	METODOLOGIA	28
4.1	Aquisição de Imagens	28
4.2	Registro das Imagens	29
4.3	Extração da Região de Interesse	30
4.4	Extração de características 1	31
4.5	Extração de Características 2	33
4.6	Redução de Características	34
4.7	Classificação	34
5	RESULTADOS PARCIAIS	35
6	CRONOGRAMA DO PLANO DE TRABALHO	36

7	CONCLUSÃO	37
7.1	Trabalhos Futuros	37
	REFERÊNCIAS	38

1 Introdução

O câncer de mama é o tipo mais comum entre as mulheres em todo o mundo, respondendo por 25% dos casos a cada ano (INCA, 2016). Quando diagnosticado tardiamente, as chances de cura são extremamente reduzidas, tornando o diagnóstico precoce um dos fatores mais importantes na redução da taxa de mortalidade desse tipo de doença. A incidência aumenta juntamente com a faixa etária, sendo que mulheres acima de 50 anos são mais suscetíveis ao desenvolvimento da patologia. No entanto, existem outros fatores de risco que implicam numa maior chance de aparecimento, como o histórico desse tipo de câncer na família, gestação tardia, terapia de reposição hormonal e exposição à radiação.

Os exames mais tradicionais na detecção do câncer de mama são os exames de toque e a mamografia. O exame de toque é um exame de triagem, onde a própria mulher pode procurar por nódulos nos seios. Porém nem sempre o câncer resulta em aparecimento de nódulos e as vezes os nódulos existentes são difíceis de detectar através do toque. Dessa forma, a mamografia se tornou um exame essencial nos dias de hoje, pois utiliza os raios-x para detectar regiões de alta densidade nas mamas. Apesar de ser o tipo de exame mais recomendado pelos especialistas, a mamografia não é passível de falhas, pois mamas com alta densidade apresentam uma dificuldade elevada na detecção de tumores, pois estes podem ficar escondidos pelo tecido denso da mama. Mulheres jovens geralmente apresentam alta densidade nas mamas, tornando a mamografia um exame não recomendável para essa faixa etária, pois utiliza a radiação na geração das imagens, o que pode futuramente causar o aparecimento do câncer na paciente. Dessa forma é necessário que outros tipo de exames sejam utilizados como forma de prevenção e diagnóstico precoce.

A termografia mamária é um exame de imagem não radioativo capaz detectar tumores que não seriam possíveis de descobrir através da mamografia. Esse tipo de exame utiliza a radiação infravermelha, emitida naturalmente pelo corpo da paciente, para detecção da doença. Regiões próximas a um tumor tendem a ter um aumento na vascularização, ocorrendo uma maior circulação de sangue na região, que causará um aumento de temperatura em relação as outras regiões da mama. Esse aumento de temperatura é detectável através da termografia, permitindo que especialistas detectem a formação de um tumor antes mesmo que ele seja palpável.

Existem duas formas na obtenção de exames de termografia mamária. A primeira delas é o que chamamos de termografia estática, onde apenas uma imagem da paciente é gerada e analisada. A segunda forma é a chamada termografia dinâmica, onde várias imagens sequenciais são geradas, permitindo que o especialista analise a evolução na distribuição de calor nas mamas da paciente. A metodologia proposta utiliza as termografias dinâmicas para auxiliar médicos especialistas no diagnóstico precoce do câncer de mama.

Durante um exame de termografia dinâmico, a paciente executa movimentos involuntários, causados pela respiração e pelo ajuste de postura, dessa forma as imagens sequenciais do exame não se encaixam perfeitamente, causando um erro que pode influenciar na metodologia. O registro de imagens deformável por *B-Splines* é utilizado para efetuar a correção desse erro. Posteriormente, extrai-se as regiões de interesse do exame, que são as mamas da paciente. Essa extração é feita de forma manual através de um aplicativo, onde o especialista deverá demarcar a região da mama. Finalmente a etapa de extração de características é executada, onde os pixels de mesma posição e diferentes tempos da termografia são analisados como uma série de tempo, produzindo um conjunto de valores estatísticos para cada pixel, formando novas imagens a partir da termografia dinâmica original. A partir dessas imagens geradas, são extraídas o conjunto de características de textura a partir de matrizes de coocorrência. Essas características podem ser reduzidas através de técnicas de redução de características como a técnica de *Análise dos Componentes Principais* e

a *Análise Discriminante Linear*. No final do processo, as características reduzidas irão servir de entrada para uma *Máquina de Vetor de Suporte* que irá ser responsável por classificar as pacientes em saudável e doente.

2 Objetivos

2.1 Objetivos Gerais

Desenvolver uma metodologia computacional que analise um exame termográfico dinâmico das mamas, a fim de encontrar padrões que diferenciem mamas saudáveis de mamas doentes.

A principal motivação do trabalho é ajudar médicos especialistas no diagnóstico precoce do câncer de mama, portanto qualquer informação que possa discriminar mamas saudáveis de mamas doentes é relevante.

2.2 Objetivos Específicos

Alguns objetivos extras são necessários para completar os objetivos gerais, sendo eles:

- Desenvolver técnicas que permitam a correção de postura em exames termográficos dinâmicos. Tais técnicas são conhecidas como registro de imagens, onde o resultado final pode variar muito de uma técnica utilizada para outra. Portanto, deve-se utilizar a que melhor se encaixe no problema.
- Analisar a variação de temperatura entre os diferentes tempos do exame, gerando características que sejam capazes de diferenciar os exames de pacientes saudáveis de exames de pacientes doentes.
- Utilizar as características extraídas para gerar um classificador automático, que seja capaz de classificar corretamente novos exames.

3 Fundamentação Teórica

Nesta seção, serão abordados os conceitos necessários para o entendimento da metodologia proposta.

3.1 A Termografia

A termografia é uma técnica que permite a visualização dos raios do espectro infravermelho de forma a mapear a temperatura de um objeto. A termografia infravermelha da mama é um tipo de exame que detecta a radiação infravermelha emitida pela superfície da mama produzindo um mapa de temperatura conhecido como termograma. A grande vantagem deste tipo de exame em relação aos exames mais conhecidos, como a mamografia, é que este não utiliza radiação no processo de obtenção das imagens e também não causa incômodo físico ao paciente, pois não é necessário a compressão das mamas, como ocorre na mamografia. Outro fator a se levar em consideração é o custo extremamente baixo e o fácil manuseio do equipamento necessário para obtenção do exame (BORCHARTT et al., 2013). A Figura 1 apresenta uma termografia em pseudo cor, onde a temperatura varia de acordo com a paleta de cores à direita da imagem.




Figura 1 – Termografia mamária.

Fonte: (SILVA et al., 2014)

3.1.1 Termografia Estática

A termografia estática (TI), é o tipo de termografia onde a medição de temperatura é feita uma única vez. No caso de TI das mamas são necessários procedimentos (SILVA et al., 2014) de preparação do ambiente e cuidados extras ao paciente para que o exame tenha resultado satisfatório, pois vários fatores podem influenciar o resultado final (SILVA, 2015).

3.1.2 Termografia Dinâmica

A termografia dinâmica (TID), é um tipo de termografia onde a mediação de temperatura é realizada através de várias etapas de tempo, ou seja, a TID mede as mudanças de temperatura sobre um determinado período de tempo. Originalmente conceituada por (ANBAR, 1987), onde notou-se que mudanças bruscas na temperatura da pele produziam informações valiosas, que não podem ser obtidas por meio de uma TI.

A TID apresenta uma característica importante na detecção de lesões mamárias, pois áreas saudáveis apresentam um comportamento distinto de áreas com algum tipo de patologia. Neoplasias são associadas com a angiogênese que causa um aumento de vascularização na região, sendo que, os vasos recém formados apresentam a características de possuir poucas terminações nervosas, o que causa um comportamento

irregular à estímulos externos, que é detectável através de um exame de termografia dinâmico (SILVA, 2015).

Na prática a TID monitora as mudanças na temperatura da pele, onde o estímulo térmico através de uma corrente de ar produz um contraste entre tecidos saudáveis e doentes. Regiões saudáveis da mama tendem a apresentar uma diminuição de temperatura com o estímulo de ar, enquanto as regiões doentes tendem a permanecer estáticas (AMALU, 2004).

3.2 Registro de Imagens

Quando imagens que foram extraídas entre diferentes tempos, pontos de vista ou aparelhos precisam ser comparadas, ocorre um problema de alinhamento das coordenadas dessas imagens. É necessário efetuar alguma forma de processamento para que essas imagens possam ser comparadas adequadamente. O *Registro de Imagens* é uma técnica que utiliza uma transformação T para mapear a posição e o valor de intensidade de um pixel p da imagem A para q na imagem B , como pode ser visto pela Equação 3.1. Figura2 mostra o efeito desse mapeamento.

$$T : p \rightarrow q \Leftrightarrow T(p) = q \quad (3.1)$$




Figura 2 – Registro de imagens é a tarefa de achar uma transformação espacial de uma imagem em outra.

Fonte: (IBANEZ et al., 2003)

Na literatura, é possível encontrar diversas definições para o problema de registro de imagens. De acordo com (BROWN, 1992), o processo de registro de imagens é transformação de conjuntos distintos de dados para um mesmo sistema de coordenadas. Em (CRUM; HARTKENS; HILL, 2014) é definido como um processo que determina correspondências entre as características de imagens extraídas em diferentes momentos, pontos de vista ou aparelhos. Tais correspondências podem ser utilizadas para aplicar transformações (rotação, translação, alongamento, etc.) em uma das imagens, de forma que seja possível a comparação entre as duas. A forma mais intuitiva de utilização do registro é para corrigir diferenças na posição entre varreduras. O registro de imagens adiciona valor à imagens, permitindo que imagens estruturais (CT, MR, ultrassom) e funcionais (PET, SPECT, funcional MRI) sejam vistas e analisadas no mesmo sistema de coordenadas, e facilita o uso de novas imagens, como para monitorar e quantificar a evolução de uma doença à medida que o tempo passa (CRUM; HARTKENS; HILL, 2014).

A Figura 3 mostra o fluxograma básico de um processo de registro de imagens. O conjunto de entrada básico de um processo de registro de imagens é composto por:

- Imagem fixa: imagem estática cujo espaço de coordenadas é o objetivo.
- Imagem móvel: imagem que será transformada para o espaço de coordenadas da imagem fixa.
- Transformação: função que irá ser responsável por mapear os pixels da imagem móvel na imagem fixa. Geralmente é responsável por dar nome ao registro.
- Métrica: uma medida que indica o quanto duas imagens são equivalentes.

- Interpolador: uma técnica para interpolar os valores da imagem móvel quando são remostrados através da transformação.
- Otimizador: o método utilizado para achar os melhores parâmetros da transformação que otimizam a métrica entre as duas imagens.




Figura 3 – Fluxograma do processo de registro de imagens.

Fonte: (PARRAGA, 2008)

3.2.1 Métricas de similaridade

As métricas de similaridade são provavelmente o elemento mais crítico no problema do registro de imagens, pois define o objetivo final do processo que é medir o quanto a imagem móvel é equivalente à imagem fixa após a transformação ser aplicada.

3.2.1.1 Correlação Cruzada Normalizada

A Correlação Cruzada Normalizada é uma métrica insensível à fatores multiplicativos entre as imagens. Produz uma função de custo com picos afiados e mínimos bem definidos. Por outro lado tem um raio de captura relativamente pequeno. Sua aplicação é limitada a imagens de mesma modalidade (adquiridas com o mesmo tipo de aparelho) (IBANEZ et al., 2003). A correlação cruzada normalizada é dada pela Equação 3.2:

$$C(f, m) = -1 \cdot \frac{\sum_{i=1}^N (f_i \cdot m_i)}{\sqrt{\sum_{i=1}^N f_i^2 \cdot \sum_{i=1}^N m_i^2}}, \quad (3.2)$$

onde f e m são os valores de pixels em forma de vetor das imagens fixa e móvel, respectivamente, i indica a posição do pixel em f e m , N é a quantidade pixels a ser considerado. Note que a equação é multiplicada por -1 . Esse fator é responsável por fazer o otimizador procurar os valores que mais se aproximem de 0, que é quando duas imagens são ditas equivalentes.

3.2.2 Transformação

A transformação é responsável por mapear os pixels da imagem móvel para a imagem fixa. Podemos dividir as transformações em dois conjuntos distintos, rígidas e deformáveis.

As transformações rígidas aplicam sobre a imagem móvel apenas transformações simples como operações de translação e rotação, dessa forma a imagem móvel não sofre deformações, sofrendo apenas o alinhamento de suas coordenadas. Registros que utilizam transformações rígidas são chamados de registro rígidos e na prática não são utilizados individualmente, pois não são capazes de corrigir erros locais que necessitam de transformações mais complexas para serem resolvidas. Apesar disso, são bastante utilizados como pré-processamento para os chamados registros deformáveis.

As transformações deformáveis são capazes de efetuar deformações nas imagens, dessa forma é possível corrigir erros que uma transformação rígida não é capaz de corrigir. Registro de imagens que utilizam esse tipo de transformação são geralmente chamados de registros não-rígidos ou deformáveis.

3.2.2.1 Translação

A translação é uma transformação rígida bastante simples. Ela mapeia todos os pontos da imagem móvel adicionando um vetor à eles. Dado um ponto 2D $p = (x, y)$, e o vetor de translação $\vec{t} = (t_x, t_y)$, podemos dizer que o ponto transladado q é dado por

$$q = p + \vec{t} = (x + t_x, y + t_y). \quad (3.3)$$

Utilizando a notação de matrizes em coordenadas homogêneas temos

$$q = \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & t_x \\ 0 & 1 & t_y \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}. \quad (3.4)$$

A Figura 4 demonstra o resultado da transformação de translação. Vemos que apenas as posições dos pixels foram alteradas.




Figura 4 – Efeito da translação.

Fonte: Elaborada pelo autor

3.2.2.2 Rotação

A rotação é uma transformação rígida capaz de rotacionar os objetos em relação a um determinado ponto. Dado um ponto $p = (x, y)$ e um ângulo de rotação θ em radianos, o ponto q é o resultado da rotação de p em θ radianos dado por

$$q = \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta & 0 \\ \sin \theta & \cos \theta & 0 \\ 0 & 0 & 1 \end{bmatrix}. \quad (3.5)$$

A Figura 5 representa uma transformação de 90° em torno da origem dos eixos.




Figura 5 – Rotação de $\theta = \frac{\pi}{2} = 90^\circ$.

Fonte: Elaborada pelo autor

Geralmente em registro de imagens, a translação e rotação são aplicadas em conjunto, para que a rotação não altere a posição do objeto. Dessa forma, aplicamos uma operação de translação para trazer o objeto para a origem das coordenadas, aplicamos a rotação, então aplicamos uma translação inversa para levar o objeto de volta para sua posição inicial.

3.2.2.3 Escala

A transformação de escala é uma transformação não-rígida capaz alterar a forma de um objeto. Dado um ponto $p = (x, y)$ e o fator de escala $s = (s_x, s_y)$, podemos dizer que o ponto q é dado por

$$q = p \cdot s = (x \cdot s_x, y \cdot s_y). \quad (3.6)$$

Em notação de matrizes homogêneas temos

$$q = \begin{bmatrix} x' \\ y' \\ 1 \end{bmatrix} = \begin{bmatrix} s_x & 0 & 0 \\ 0 & s_y & 0 \\ 0 & 0 & 1 \end{bmatrix} \cdot \begin{bmatrix} x \\ y \\ 1 \end{bmatrix}. \quad (3.7)$$

Na Figura 6 vemos o efeito da transformação de escala. Caso os parâmetros sejam iguais $s_x = s_y$, não mudamos a forma do objeto. Porém, caso $s_x \neq s_y$, temos uma transformação que altera a forma do objeto transformado.




Figura 6 – Transformação de escala.

Fonte: Elaborada pelo autor

3.2.2.4 Transformações FFD baseadas em *B-Splines* cúbicas

Um dos tipos de transformações não-rígidas mais comuns atualmente são as chamadas transformações FFD (deformação de forma livre) baseadas em *B-splines* cúbicas (YIN; HOFFMAN; LIN, 2009). A ideia

básica desse tipo de transformação é manipular a grade de pixels a partir dos chamados pontos de controle. Essa manipulação permite criar um campo de deslocamento, que irá mapear os pixels da imagem móvel.




Figura 7 – O conceito de campo de deslocamento. Para cada posição de pixel na imagem móvel, existe uma direção e distância que ele precisa se mover para se assemelhar à imagem fixa.

Fonte: (SCHWARZ, 2007)

Seja Φ a grade uniforme de dimensões $n_x \times n_y \times n_z$ com $\Phi_{i,j,k}$ representando o deslocamento do ijk -ésimo ponto de controle. O espaço entre as grandes de controle nas direções x , y e z são denotadas por δ_x , δ_y e δ_z , respectivamente. A transformação $T(x : \Phi)$ é definida por

$$T(x : \Phi) = \sum_{l=0}^3 \sum_{m=0}^3 \sum_{n=0}^3 \beta_l(u) \beta_m(v) \beta_n(w) \Phi_{i+l, j+m, k+n}, \quad (3.8)$$

onde os parâmetros são dados por

$$i = \left\lfloor \frac{x}{\delta_x} \right\rfloor - 1, \quad (3.9)$$

$$j = \left\lfloor \frac{y}{\delta_y} \right\rfloor - 1, \quad (3.10)$$

$$z = \left\lfloor \frac{z}{\delta_z} \right\rfloor - 1, \quad (3.11)$$

$$u = \frac{x}{\delta_x} - (i + 1), \quad (3.12)$$

$$v = \frac{y}{\delta_y} - (j + 1), \quad (3.13)$$

$$w = \frac{z}{\delta_z} - (z + 1). \quad (3.14)$$

As funções β são *B-splines* cúbicas e definidas por

$$\beta_0(t) = (-t^3 + 3t^2 - 3t + 1)/6, \quad (3.15)$$

$$\beta_1(t) = (3t^3 - 6t^2 + 4)/6, \quad (3.16)$$

$$\beta_2(t) = (-3t^3 + 3t^2 + 3t + 1)/6, \quad (3.17)$$

$$\beta_3(t) = t^3/6, \quad (3.18)$$

onde $0 \leq t \leq 1$.

Um parâmetro muito importante desse tipo de transformação é a resolução da grade de controle, pois a partir dela serão gerados os campos de deslocamentos. Uma grade muito espaçosa permite a modelagem de transformações deformáveis globais, enquanto uma grade mais fina modela deformações altamente locais (YIN; HOFFMAN; LIN, 2009).

3.2.3 Interpolador

No processo do registro, a métrica geralmente compara os valores de intensidade dos pixels da imagem fixa com os pixels correspondentes na imagem móvel transformada. Quando transformamos um ponto de um espaço para o outro através de uma transformação, este geralmente irá ser mapeado para uma posição fora da grade de pixels da imagem (Figura 8). A função do interpolador é calcular o valor de intensidade em uma dada posição de forma correta (IBANEZ et al., 2003).




Figura 8 – Posições de grade da imagem fixa mapeadas para posições fora da grade na imagem móvel.

Fonte: (IBANEZ et al., 2003)

3.2.3.1 Interpolador Linear

O interpolador linear assume que os valores de intensidade dos pixels variam de forma linear entre as posições de grade. Dessa forma, os valores interpolados serão contínuos espacialmente, porém o gradiente de intensidade será descontinuo na grade. Se dois pontos conhecidos são dados por (x_0, y_0) e (x_1, y_1) a interpolação linear é dada pela Equação 3.19.

$$y = y_0 + (y_1 - y_0) \frac{x - x_0}{x_1 - x_0} \quad (3.19)$$

3.2.4 Otimizador

Como dito anteriormente, o papel do otimizador é encontrar os melhores parâmetros para a transformação escolhida no processo de registro de imagens. Dessa forma, um amplo conjunto de otimizadores podem ser utilizados, como os *Algoritmos Genéticos* (WHITLEY, 1994) e o *Gradiente Descendente* (BURGES et al., 2005).

3.2.4.1 LBFGS

O *LBFGS* (Limited-memory Broyden-Fletcher-Goldfarb-Shanno) é um método de otimização bastante comum em problemas de registro de imagens. De acordo com (SHEPPARD; TERRELL; HENKELMAN,

2008), é um método quasi-Newton que constrói informações sobre as segundas derivadas durante a otimização e utiliza essa informação para avançar em direção ao mínimo harmônico previsto. Mais especificamente, a inversa da matriz hessiana H^{-1} é construída iterativamente, começando a partir da matriz diagonal. O método pode ser utilizado de duas formas. Na primeira, uma direção de busca,

$$d_j = F_j H_j^{-1}, \quad (3.20)$$

é identificada em cada iteração, e a minimizador de linha é utilizado para avançar na direção,

$$R_{j+1} = R_j + \lambda d_j. \quad (3.21)$$

A segunda forma é utilizar H^{-1} diretamente para calcular o avanço,

$$R_{j+1} = R_j + F_j H^{-1}. \quad (3.22)$$

O LBFGS utiliza a memória da iteração anterior para construir H^{-1} . O número de iterações é um parâmetro variável e é definido pelo usuário.

3.3 Matrizes de Coocorrência de Níveis de Cinza

A análise de textura em imagens é uma técnica importante na identificação de características em imagens digitais. Uma das primeiras técnicas utilizadas para a extração dessas características foram as matrizes de coocorrências de níveis de cinza também chamadas de *GLCMs* (Gray Level Co-occurrence Matrix) originalmente propostas em (HARALICK; SHANMUGAM; DINSTEN, 1973). Desde então elas vem sendo bastante utilizadas em várias aplicações de análise de textura e permanecem sendo uma ferramenta importante no domínio de análise de texturas (SEBASTIAN et al., 2012).

A GLCM é uma técnica utilizada para extrair características estatísticas de textura de segunda ordem (ALBREGTSEN et al., 2008), ou seja, a medição considera a relação entre pares de pixels, geralmente vizinhos (HALL-BEYER,).

3.3.1 Construção de uma GLCM

Seja I uma imagem em níveis de cinza e N a quantidade de níveis de cinza, uma GLCM G é uma matriz quadrada de ordem N (SEBASTIAN et al., 2012). O elemento da matriz $P(i, j | \Delta x, \Delta y)$ é a frequência relativa em que dois pixels de intensidade (i, j) , separados por uma distância $(\Delta x, \Delta y)$, são vizinhos. Também é possível dizer que o elemento $P(i, j | d, \theta)$ contém os valores da probabilidade de segunda ordem para mudanças entre os níveis de cinza i e j em uma distância d e um ângulo θ (ALBREGTSEN et al., 2008).

Seja I uma imagem de dimensões $W \times H$, então uma GLCM de I é definida pela Equação 3.23.

$$G(i, j | \Delta x, \Delta y) = \sum_{p=1}^W \sum_{q=1}^H A \quad (3.23)$$

$$A = \begin{cases} 1, & \text{se } I(p, q) = i \text{ e } I(p + \Delta x, q + \Delta y) = j \\ 0, & \text{caso contrário} \end{cases} \quad (3.24)$$

Como exemplo temos uma imagem I de dimensões 5×5 , com 4 níveis de cinza. Então as matrizes de coocorrência $G(i, j | \Delta x = 1, \Delta y = 0)$ e $G(i, j | \Delta x = 1, \Delta y = 1)$ são representadas abaixo.

$$I = \begin{bmatrix} 2 & 0 & 2 & 1 & 1 \\ 2 & 1 & 2 & 3 & 1 \\ 3 & 1 & 3 & 2 & 0 \\ 0 & 0 & 1 & 2 & 2 \\ 3 & 3 & 3 & 1 & 1 \end{bmatrix}$$

$$G(i, j | \Delta x = 1, \Delta y = 0) = \begin{bmatrix} 1 & 1 & 1 & 0 \\ 0 & 2 & 2 & 1 \\ 2 & 2 & 1 & 1 \\ 0 & 3 & 1 & 2 \end{bmatrix}$$

$$G(i, j | \Delta x = 1, \Delta y = 1) = \begin{bmatrix} 0 & 0 & 1 & 2 \\ 0 & 3 & 0 & 1 \\ 0 & 3 & 2 & 1 \\ 2 & 0 & 1 & 0 \end{bmatrix}$$

3.3.2 GLCM Normalizada

Considere $N = \sum_i \sum_j G_d(i, j)$, que é a quantidade de ocorrências de pares em G_d . Seja $GN_d(i, j) = \frac{1}{N} G_d(i, j) \cdot N$, chamada de GLCM normalizada, onde as entradas (i, j) de $GN_d(i, j)$ são as probabilidades de coocorrência de um determinado pixel com intensidade i ser separado de um pixel de intensidade j por uma distância k em uma determinada direção d (SEBASTIAN et al., 2012).

3.3.3 Características de Textura

A partir de uma GLCM, é possível extrair um conjunto de características que descrevem a textura de determinada imagem (ALBREGTSEN et al., 2008), disponíveis em (HARALICK; SHANMUGAM; DINSTEN, 1973; HARALICK, 1979; CONNERS; TRIVEDI; HARLOW, 1984). De acordo com (HALL-BEYER,) temos as seguintes características que podem ser extraídas a partir de uma GLCM:

$$Contraste = \sum_{i,j=0}^{N-1} P_{i,j} (i - j)^2 \quad (3.25)$$

$$Dissimilaridade = \sum_{i,j=0}^{N-1} P_{i,j} |i - j| \quad (3.26)$$

$$Homogeneidade = \sum_{i,j=0}^{N-1} \frac{P_{i,j}}{1 + (i - j)^2} \quad (3.27)$$

$$ASM = \sum_{i,j=0}^{N-1} P_{i,j}^2 \quad (3.28)$$

$$Energia = \sqrt{ASM} \quad (3.29)$$

$$Correlação = \sum_{i,j=0}^{N-1} P_{i,j} \left[\frac{(i - \mu_i) \cdot (j - \mu_j)}{\sqrt{(\sigma_i^2) \cdot (\sigma_j^2)}} \right] \quad (3.30)$$

$$\mu_i = \sum_{i,j=0}^{N-1} i \cdot (P_{i,j}) \quad (3.31)$$

$$\mu_j = \sum_{i,j=0}^{N-1} j \cdot (P_{i,j}) \quad (3.32)$$

$$\sigma_i^2 = \sum_{i,j=0}^{N-1} P_{i,j} (i - \mu_i)^2 \quad (3.33)$$

$$\sigma_j^2 = \sum_{i,j=0}^{N-1} P_{i,j} (j - \mu_j)^2 \quad (3.34)$$

onde N é quantidade de níveis de cinza $P_{i,j}$ é a frequência de um par de pixels i e j serem vizinhos.

3.4 Redução de Dimensionalidade

Em *Aprendizado de Máquina*, geralmente possuímos um conjunto de dados previamente disponíveis. Nesse conjunto de dados, cada indivíduo é representado por um conjunto de características extraídas do dado original. Por exemplo, em imagens de níveis de cinza é possível extrair as características a partir de uma GLCM. A quantidade de características que um indivíduo possui é o que chamamos de *dimensão*. Para um conjunto de dados de dimensão $D = 6$, então temos 6 características que descrevem cada indivíduo.

É fácil pensar que quanto maior o número de características, melhor para discriminar os indivíduos. Porém, um conjunto de dados com uma dimensão muito alta implica maior complexidade no problema de classificação. Outro problema é que, em muitos casos, nem todas as características são consideradas importantes para o entendimento de um certo problema (FODOR, 2002).

Em termos matemáticos, o problema de *Redução de Dimensionalidade* pode ser descrito da seguinte forma: Dado um conjunto de dados com p dimensões $x = (x_1, x_2, \dots, x_p)^T$, encontrar uma representação de menor dimensão $s = (s_1, s_2, \dots, s_k)^T$, onde $k \leq p$, que seja capaz de capturar o conteúdo dos dados originais, de acordo com um critério preestabelecido (FODOR, 2002).

Algumas técnicas de redução de dimensionalidade são descritas abaixo.

3.4.1 Seleção de Características Univariada

A seleção de características univariada seleciona as melhores características baseada em testes estatísticos univariados (LEARN,). Por exemplo, podemos selecionar as K melhores características através de um teste estatístico que classifique as características que melhor separam as classes de indivíduos de um conjunto de dados.

3.4.2 Análise de Componentes Principais

A Análise de Componentes Principais (PCA) é uma técnica de redução linear (JACKSON, 2005). Por ser baseada na matriz de covariância dos dados, é um método de segunda ordem. O PCA reduz a dimensionalidade encontrando os *principais componentes* (PCs) do conjunto de dados com maior variância, que são vetores formados pelas combinações das características originais. Por exemplo, o primeiro PC é o que possui maior variância, Temos $s_1 = x^T w_1$, onde o vetor de coeficientes de p dimensões é $w_1 = (w_{1,1}, \dots, w_{1,p})^T$ que resolve:

$$w_1 = \arg \max_{\|w\|=1} \text{Var}\{x^T w\} \quad (3.35)$$

O segundo PC é a combinação linear com a segunda maior variância e ortogonal ao primeiro PC, e assim sucessivamente. Existem tantos PCs quanto o número de características originais (FODOR, 2002).

Geralmente, normaliza-se os dados antes da aplicação do PCA, pois o método é dependente da escala. Um dos métodos possíveis para a normalização é escalar cada características entre 0 e 1. Então, assumindo que os dados estão normalizados, podemos calcular a matriz de covariância

$$C = \frac{1}{p-1} \sum_{i=1}^p (x_i - \bar{x}) \cdot (x_i - \bar{x})^T, \quad (3.36)$$

onde \bar{x} é o vetor médio dado por

$$\bar{x} = \frac{1}{p} \sum_{i=1}^p x_i. \quad (3.37)$$

Utilizando a relação

$$Cv = \lambda v, \quad (3.38)$$

onde v é um autovetor de C e λ o seu respectivo autovalor. Cada autovetor corresponde a um PC, e os respectivos autovalores indicam o grau de variância de cada PC. Assim, escolhendo os k PCs com maior variância absoluta, podemos mapear nossos dados originais em um novo conjunto

$$S = W^T X, \quad (3.39)$$

onde X é o conjunto de dados originais e W uma matriz de transformação

$$W = (v_1, \dots, v_k), \quad (3.40)$$

onde v_1 é o PC de maior variância e v_k o k -ésimo PC de maior variância.

É uma técnica muito útil quando queremos transformar nossas características originais, onde alguma delas não oferecem muita variação nos dados, em um espaço novo com menor dimensão onde as novas características possuem uma melhor dispersão nos dados. A Figura 9 mostra um conjunto de indivíduos gerados por distribuições normais multivariadas com 3 características. Utilizando o PCA para reduzir o espaço dimensional para apenas 2, temos a Figura 10, que exemplifica o efeito da redução.




Figura 9 – Amostras geradas utilizando um distribuição normal multivariada.

Fonte: Elaborada pelo autor

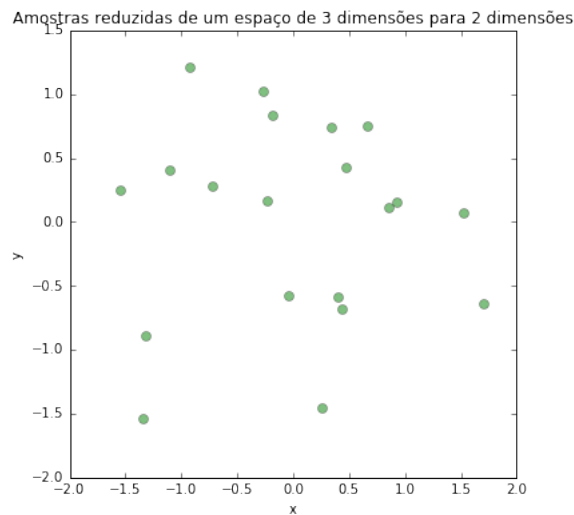


Figura 10 – Amostras reduzidas para o espaço bidimensional utilizando os dois principais componentes.

Fonte: Elaborada pelo autor

3.4.3 Análise Discriminante Linear

A Análise Discriminante Linear (LDA) é uma técnica similar ao PCA, onde buscamos combinações lineares das características para formar um novo espaço de dimensões reduzidas. A diferença é que ao contrário do PCA que busca combinações com maior variância entre os dados, o LDA procura combinações que melhor separam as classes de um determinado problema, portanto podemos dizer que o LDA é uma técnica supervisionada, pois precisamos conhecer as classes que cada indivíduo pertence.

Normalmente é utilizado para redução de dimensionalidade, como um pré-processamento de técnicas de aprendizado de máquina e reconhecimento de padrões (RASCHKA,). Também é possível utilizar o LDA como um classificador. Originalmente proposto em (FISHER, 1936) como um problema *2-class*, que foi generalizado para um problema *multi-class* em (RAO, 1948).

Considerando um conjunto de observações X de dimensões $k \times p$, em que k corresponde à quantidade de indivíduos e p à quantidade de características de cada indivíduo. Para cada indivíduo em X , existe um




Figura 11 – Distância intra-classe.

Fonte: Elaborada pelo autor

elemento em y que indica a classe ao qual pertence. O objetivo é encontrar uma transformação W , que maximize a distância entre classes (Figura 12) e minimize a distância intra-classe (Figura 11).




Figura 12 – Distância inter-classes.

Fonte: Elaborada pelo autor

Dessa forma W mapeia X em \bar{X} através da Equação 3.41

$$\bar{X} = W^T \cdot X \quad (3.41)$$

onde W é formado pelos m autovetores com maiores autovalores absolutos da matriz S dada pela Equação 3.42. Uma observação importante é que $m < c - 1$, onde c é a quantidade de classes que existem em y (RASCHKA,).

$$S = S_W^{-1} \cdot S_B \quad (3.42)$$

A matriz S_W é o que chamamos de matriz de dispersão intra-classe e é definida por:

$$S_W = \sum_{i=1}^c S_i \quad (3.43)$$

$$S_i = \sum_{x \in c_i}^n (x - \mu_i) \cdot (x - \mu_i)^T \quad (3.44)$$

$$\mu_i = \frac{1}{n_i} \sum_{x \in c_i}^n x_k \quad (3.45)$$

onde, S_i é matriz de dispersão da classe c_i e μ_i é o vetor que representa os valores médios de cada característica de indivíduos que pertencem a classe c_i .

A matriz S_B é chamada de matriz de dispersão inter-classes e é definida por:

$$S_B = \sum_{i=1}^c N_i (\mu_i - \mu) \cdot (\mu_i - \mu)^T \quad (3.46)$$

onde, N_i é a quantidade de indivíduos que pertencem a classe c_i e μ é o vetor que representa a média das características de todos os indivíduos em X .

A vantagem de utilizar o LDA é que simplificamos o problema de classificação criando novas características, a partir das originais, que melhor separam as classes do conjunto de dados. A grande desvantagem é que não é possível saber quais características originais tem maior peso, pois os discriminantes são formados a partir de combinações lineares de todas elas. A Figura 13 apresenta um conjunto de indivíduos que pertencem a três classes distintas. Cada classe foi gerada a partir de uma distribuição normal multivariada, onde os parâmetros diferem entre elas. A Figura 14 apresenta o resultado da aplicação do LDA para efetuar a redução do espaço tridimensional para bidimensional.




Figura 13 – Amostras geradas de distribuições normais multivariadas.

Fonte: Elaborada pelo autor




Figura 14 – Resultado da aplicação do LDA para reduzir as amostras da Figura 13.

Fonte: Elaborada pelo autor

3.5 Máquinas de Vetor de Suporte

Problemas de classificação geralmente envolvem classificar se um certo indivíduo pertence à classe A, B ou C . Atualmente existem diversas técnicas de aprendizado de máquina capazes de realizar essa tarefa com êxito e umas das principais técnicas utilizadas hoje em dia são as Máquinas de Vetor de Suporte (SVM). Foram originalmente propostas por (CORTES; VAPNIK, 1995) como um classificador binário, capaz de dizer se um determinado indivíduo pertence à classe A ou B . São parte do grupo de técnicas de aprendizado supervisionado, onde é necessário conhecer previamente um conjunto de indivíduos para que o algoritmo gere um modelo que seja capaz de prever qual a classe uma nova entrada pertence.

Uma SVM constrói hiperplanos em um espaço de alta dimensão, que pode ser utilizado para a tarefa de classificação. Uma boa separação é obtida através do hiperplano que possui maior distância entre os pontos mais próximos de cada classe no conjunto de dados de treino (LEARN,).




Figura 15 – Construção de hiperplanos.

Fonte: (LEARN,)

De acordo com (SILVA, 2015), dado (x_k, y_k) o conjunto de amostras para treinamento, sendo que $x_i \in \mathbb{R}^n$ correspondente ao vetor de características do indivíduo i , $y_i \in \{1, -1\}$ corresponde à classe do indivíduo i , sendo $i = 1, 2, \dots, k$. O objetivo do problema de classificação é encontrar uma função $f(x) : \mathbb{R}^n \rightarrow \{1, -1\}$ que seja capaz de estimar corretamente a classe do indivíduo x .

Na etapa de treinamento a função $f(x) = (w \cdot x) + b$ é estimada, de forma que a seguinte relação seja satisfeita:

$$y_i((w \cdot x_i) + b) \geq 1 \quad (3.47)$$

onde w é o vetor normal ao hiperplano e b a distância da função f em relação à origem. Os valores ótimos de w e b são encontrados de acordo com a restrição dada pela Equação 3.47 ao minimizar a equação:

$$\phi(w) = \frac{w^2}{2} \quad (3.48)$$




Figura 16 – Vetores de suporte.

Fonte: Elaborada pelo autor

O SVM possibilita encontrar um hiperplano que minimize a ocorrência de erros nos casos em que a separação ótima entre as classes não seja possível. Com a utilização de variáveis de folga, é possível relaxar a restrição da Equação 3.47. Dessa forma o SVM resolve problema de otimização:

$$\min \phi(w, \zeta) = \frac{w^2}{2} C \sum_{i=1}^N \zeta_i \quad (3.49)$$

sujeito à:

$$y_i((w \cdot x_i) + b) + \zeta_i \geq 1 \quad (3.50)$$

onde C é um parâmetro de treinamento que define o equilíbrio entre a complexidade do modelo e o erro de treinamento.

Utilizando a teoria dos multiplicadores de Lagrange é possível obter:

$$L(a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i,j=1}^N a_i a_j y_i y_j (x_i, x_j) \quad (3.51)$$

Assim, o objetivo passa a ser encontrar os multiplicadores de Lagrange a_i ótimos que satisfaçam a Equação 3.52 (CHAVES, 2006).

$$\sum_{i=1}^N a_i y_i = 0, \quad 0 \leq a_i \leq C \quad (3.52)$$

Apenas os pontos onde a restrição imposta pela Equação 3.47 é igual 1, tem correspondentes $a_i \neq 0$. Esses pontos são chamados de vetores de suporte, e estão geometricamente sobre as margens, possuindo grande importância na definição do hiperplano ótimo, pois delimitam as margens do conjunto de treinamento. Na Figura 16, os vetores de suporte são representados por círculos circunscritos.

Pontos além da margem não tem influência suficiente para determinar o hiperplano, porém esses vetores de suporte são essenciais nessa tarefa.

Agora considere o conjunto de amostras da Figura 17. Vemos que não é possível traçar uma reta capaz de separar as classes, tornando o problema um caso não-linear. De acordo com (SILVA, 2015), necessitamos

de uma transformação não-linear capaz de mapear o conjunto original (espaço dados) para um novo espaço (espaço de características). Esse novo espaço deve apresentar dimensões suficientes para que seja possível realizar a separação linear do conjunto de dados. Dessa forma, o hiperplano de separação é definido como uma função linear de vetores retirados do espaço de características e não do espaço de dados. A construção desse conjunto depende de uma função K , chamada de *kernel* (HAYKIN, 2001). A Equação 3.53 apresenta a forma modificada da 3.52 utilizando uma função K .




Figura 17 – Conjunto de indivíduos não separáveis linearmente.

Fonte: Elaborada pelo autor

$$L(a) = \sum_{i=1}^N a_i - \frac{1}{2} \sum_{i,j=1}^N a_i a_j y_i y_j K(x_i, x_j) \quad (3.53)$$

Um conjunto de funções amplamente utilizadas em conjunto com uma SVM para classificação de dados não linearmente separáveis são as funções de base radial (RBF). Uma função RBF é definida por:

$$K(x_i, y_i) = \exp(-\gamma \|x_i - y_i\|^2) \quad (3.54)$$

onde $\gamma = 1/\sigma^2$, onde σ é a variância.

4 Metodologia

Nesta seção, são apresentados os procedimentos propostos para a realização dos objetivos descritos na Seção 2. A Figura 18 apresenta o fluxo das etapas executadas.




Figura 18 – Fluxograma da metodologia.

Fonte: Elaborada pelo autor

4.1 Aquisição de Imagens

A aquisição de imagens é uma etapa crucial na metodologia proposta, pois sem imagens para casos de teste não é possível validar a metodologia. Atualmente existem poucos bancos de imagem termográficas mamárias disponíveis para o público geral, sendo a maioria deles de propósito privado. As imagens utilizadas neste trabalho são provenientes do *Database for Mastology Research with Infrared Image - DMR-IR*, acessível através da interface on-line <<http://visual.ic.uff.br/dmi>>. Mais informações sobre a base de imagens utilizada podem ser encontradas em (??) e (SILVA et al., 2014).

De acordo com (SILVA et al., 2014), no protocolo de termografias dinâmicas as pacientes são submetidas a um estresse térmico causado pela refrigeração por um ventilador elétrico. Quando a média de temperatura entre as mamas é de 30.5°C (Figura 19), ou 5 minutos de estresse foram aplicados, a refrigeração é interrompida e a aquisição sequencial das imagens é iniciada, extraindo um total de 20 imagens sequenciais com intervalos de tempo fixos.




Figura 19 – Monitoramento da temperatura média para começar a aquisição sequencial.

Fonte: (SILVA et al., 2014)

As imagens utilizadas possuem dimensão de 640 pixels de largura e 480 pixels de largura e foram utilizados os valores de temperatura (em graus celsius) obtidos diretamente da câmera termográfica utilizada na

aquisição. A Figura 20 apresenta essas matrizes são armazenadas em formato *.txt*, onde cada exame é composto por 20 arquivos separados por tempo de aquisição.

30.53	30.51	30.68	30.89	30.83	30.84	30.82	30.47	30.73	30.66	30.68	30.56	30.61	30.63	30.55	30.63	30.72	30.74	30.56
30.74	30.96	30.72	30.77	30.81	30.8	30.88	30.9	30.9	30.99	30.9	30.98	31.15	30.91	30.88	31.12	30.93	31.01	31.05
31.06	31.12	31.09	31.05	31.08	31.05	30.95	30.68	30.74	30.57	30.6	30.32	30.41	30.26	30.3	29.95	30.15	30.02	29.95
29.95	29.94	30.11	29.98	30.09	30.21	30.2	30.32	30.29	30.43	30.32	30.5	30.61	30.8	30.71	30.72	30.63	30.41	30.17
29.69	29.49	29.21	29.15	29.08	28.95	29.06	28.86	28.86	28.86	28.58	28.67	28.7	28.5	28.44	28.51	28.42	28.38	28.5
28.3	28.51	28.5	28.5	28.55	28.7	28.55	28.63	28.63	28.76	28.55	28.71	28.6	28.53	28.34	28.32	27.72	26.33	25.18
24.93	24.84	24.92	24.81	24.76	24.77	24.97	24.9	24.76	24.95	24.87	25.04	24.78	24.85	24.81	24.84	24.9	24.83	24.86
24.94	24.85	24.92	24.97	25.06	25.22	25.23	25	24.97	25.04	25.1	24.95	25.03	25.06	24.98	25.22	25.31	25.38	25.36
25.35	25.64	25.77	26.29	27.21	28.27	29.46	29.79	29.77	29.95	29.95	29.88	29.93	30.29	30.38	30.4	30.24	30.23	29.98
29.43	29.25	29.82	29.05	28.89	29.03	28.89	28.9	28.86	28.95	28.86	28.95	29.18	29.13	29.15	29.26	29.37	29.39	29.38
29.53	29.55	29.54	29.8	29.65	29.84	29.94	30.16	30.16	30.56	30.81	31.23	31.43	31.61	32.01	32.1	32.28	32.28	32.21
32.47	32.59	32.58	32.79	33.08	33.09	33.08	33.83	32.83	32.89	32.66	32.71	32.69	32.64	32.64	32.58	32.62	32.62	32.58
32.55	32.65	32.58	32.48	32.45	32.41	32.31	32.36	32.34	32.32	32.25	32.34	32.3	32.4	32.43	32.32	32.29	32.33	32.33
32.36	32.4	32.39	32.48	32.41	32.49	32.55	32.63	32.61	32.75	32.78	32.91	32.95	33.07	33.14	33.19	33.34	33.41	33.4
33.6	33.6	33.72	33.62	33.61	33.67	33.55	33.37	33.14	33.15	32.92	32.7	32.35	32.37	32.33	32.03	31.95	31.92	31.84
31.33	31.15	30.73	30.73	30.14	29.86	29.7	29.38	29.32	29.09	29.07	29.11	29.1	28.89	28.87	28.88	28.89	29.01	28.87
28.85	28.87	29.05	28.98	29.02	29.05	28.93	29.14	28.99	29.07	29.05	29.23	29.07	29.31	29.32	29.42	29.48	29.69	29.91
30.25	30.34	30.44	30.35	30.4	30.35	30.35	30.22	30.15	29.97	29.6	29.38	28.27	27.27	26.61	26.13	26.12	25.79	25.73
25.68	25.7	25.57	25.6	25.6	25.58	25.66	25.39	25.42	25.32	25.4	25.37	25.51	25.39	25.49	25.47	25.23	25.47	25.25
25.25	25.25	25.09	25.11	25.17	25.06	25.06	25.15	24.96	25.02	24.98	25.17	25	25.22	24.93	25.19	25.01	25.04	25.18
25.12	25.09	25.1	25.15	25.06	25.11	25.06	25.06	25.2	25.2	25.19	24.96	25.15	25.04	25	24.98	25.1	25	25.05
24.94	25.26	24.95	25.21	25.05	25.21	25.05	25.08	25.07	25.22	25.08	25.18	25.22	25.1	25.1	24.97	25.11	25.04	25.16
25.4	25.9	26.16	26.95	28.11	28.86	29.24	29.3	29.62	29.7	29.7	30.01	30.3	30.55	30.83	30.87	31.06	31.07	31.04
31.22	31.23	31.24	31.29	31.34	31.43	31.35	31.34	31.31	31.29	31.3	31.34	31.29	31.33	31.27	31.34	31.31	31.38	31.29
31.31	31.25	31.31	31.28	31.24	31.29	31.28	31.23	31.35	31.36	31.26	31.26	31.17	31.33	31.04	30.91	31.15	31.11	30.98
30.99	31.01	31.17	30.95	31	30.79	30.76	30.65	30.74	30.61	30.65	30.49	30.5	30.38	30.57	30.35	30.31	30.39	30.38
30.42	30.23	30.27	30.3	30.68	30.23	30.19	30	30.01	30	29.79	29.58	29.54	29.56	29.5	29.51	29.25	29.39	29.27
29.17	28.97	29.11	28.99	28.84	28.74	28.61	28.81	28.6	28.57	28.43	28.64	28.6	28.43	28.58	28.46	28.53	28.52	28.24
25.71	26.57	26.93	26.83	26.84	27.03	27.16	27.15	27.29	27.31	27.3	27.31	27.53	27.48	27.68	27.89	27.85	27.85	27.91
27.9	28	28.01	28.14	28.25	28.34	28.27	28.25	28.47	28.38	28.38	28.59	28.6	28.6	28.76	28.78	28.79	28.9	29.01
28.99	29.01	29.1	29.11	29.07	29.17	29.19	29.2	29.32	29.37	29.4	29.4	29.42	29.44	29.59	29.59	29.52	29.64	29.65
29.67	29.63	29.74	29.78	29.79	29.76	29.71	29.83	29.87	29.83	29.99	30.01	29.93	30.17	30.09	30.23	30.31	30.43	30.41
30.71	30.78	30.86	30.87	30.77	30.83	30.72	30.75	30.78	30.62	30.65	30.64	30.62	30.6	30.69	30.65	30.75	30.82	30.65
30.85	30.89	30.95	30.98	30.91	30.94	30.99	30.95	31.12	31.11	31.03	31.16	31.14	30.92	31.12	31.13	31.15	31.14	31.22
31.24	31.26	31.18	31.14	31.14	31.14	31.01	30.98	30.9	30.65	30.61	30.59	30.61	30.49	30.3	30.3	29.98	30.14	30.12
29.97	30.08	30.11	30.07	30.12	30.26	30.34	30.31	30.3	30.43	30.44	30.59	30.74	30.79	30.85	30.85	30.87	30.63	30.39
29.69	29.59	29.46	29.4	29.08	29.07	29.05	28.87	28.89	28.87	28.59	28.62	28.65	28.5	28.47	28.55	28.49	28.4	28.39
28.15	28.48	28.5	28.52	28.65	28.64	28.7	28.66	28.73	28.68	28.6	28.61	28.59	28.66	28.58	28.51	27.4	27.45	24.91

Figura 20 – Matriz de temperatura.

Fonte: (SILVA, 2015)

No total foram utilizados 70 exames previamente diagnosticados para aplicação desta metodologia, sendo que 35 são de pacientes saudáveis e os 35 restantes de pacientes que apresentam algum tipo de anomalia nas mamas.

4.2 Registro das Imagens

Durante o protocolo de aquisição de imagens, é natural que a paciente execute movimentos involuntários causados pela respiração e ajuste de postura. Esses movimentos causam diferenças espaciais de uma sequência para a outra. As Figuras 21a e 21b são termogramas sequências de tempos $t = 1$ e $t = 2$, respectivamente. A Figura 21c apresenta a diferença quadrática $d = (P_t(i, j) - P_t(i, j))^2$, onde (i, j) é a posição do pixel, sendo $i = 0, \dots, 639$ e $j = 0, \dots, 479$, e $P_t(i, j)$ é o valor de pixel na posição (i, j) no tempo t . É possível notar que existe uma diferença causada pela movimentação involuntária da paciente.




Figura 21 – Termogramas de tempos distintos. Tons mais claros denotam uma maior diferença entre as regiões.

Fonte: Elaborada pelo autor.

Para analisar as sequências de termogramas de um determinado exame é necessário corrigir essas diferenças, dessa forma o registro de imagens é uma etapa essencial de pré-processamento das termografias. Para a

construção do registro, as seguintes técnicas foram utilizadas:

- Métrica: Correlação Cruzada Normalizada (Seção 3.2)
- Transformação: *B-Splines* (Seção 3.2.2.4)
- Interpolador: Linear (Seção 3.2.3.1)
- Otimizador: LBFGS (Seção 3.2.4.1)

Utilizando a primeira sequência do conjunto de termograma como imagem fixa, executamos o algoritmo de registro 19 vezes, sendo que as sequências restantes são as imagens móveis. A Figura 22 demonstra a utilização do registro construído, na Figura 21b como imagem móvel e tendo a Figura 21a como imagem fixa.




Figura 22 – Resultado da aplicação do registro na Figura 21b como móvel e a Figura 21a como fixa. Note que a diferença de postura foi corrigida, deixando a imagem majoritariamente escura.

4.3 Extração da Região de Interesse

Essa etapa consiste em extrair a região de interesse (ROI) da imagem. Como a metodologia tem o objetivo de detectar anomalias no padrão de vascularização das mamas, é de interesse que as demais regiões de uma TID sejam excluídas do processo. Alguns métodos de segmentação automática são encontrados na literatura (MARQUES, 2012), porém existem limitações que não tornam possíveis a utilização desse tipo de técnica. Dessa forma, a região de interesse é extraída de forma manual, através da utilização de um programa de visualização e edição de imagens.

Apesar de cada TID possuir um total de 20 sequências de termogramas, utilizamos apenas a sequência no tempo inicial para gerar uma máscara responsável por demarcar a ROI segmentada manualmente através do software ImageJ (ABRÀMOFF; MAGALHÃES; RAM, 2004; RASBAND; IMAGEJ et al., 1997). Utilizando a máscara da sequência inicial é possível extrair as ROIs das demais sequências após a aplicação do registro dos termogramas (Seção 4.2). A Figura 23a demonstra a etapa de segmentação manual utilizando o mouse para desenhar o polígono que definirá a ROI. Como resultado uma máscara

binária (Figura 23b) é gerada, para ser utilizada como ROI para todos as 20 seqüências de termogramas em um exame.




Figura 23 – Extração da região das mamas através do software ImageJ.

Fonte: (SILVA, 2015)

4.4 Extração de características 1

Dado um exame TID, temos 20 seqüências de termogramas, cada um correspondendo à um tempo distinto em ordem sequencial. Precisamos extrair características que diferenciem as TID de pacientes saudáveis de TID de pacientes com algum tipo de anomalia. A forma encontrada foi criar um vetor $p = [I_1(i, j), I_2(i, j), \dots, I_{20}(i, j)]$, onde $I_t(i, j)$ é o valor de temperatura do termograma de tempo t na posição (i, j) . Dessa forma, podemos extrair 4 valores estatísticos do vetor p , sendo eles:

- A temperatura de inicial, ou seja, o valor de $I_1(i, j)$. Notamos que a temperatura inicial da seqüência de termogramas é um bom discriminador, pois regiões com anomalias tendem a ficar mais definidas durante o processo de resfriamento no protocolo de aquisição de imagens e não possuem regiões equivalentes na mama oposta. A Figura 24 mostra a diferença entre uma TID saudável e outra com anomalia.
- O ganho de temperatura total dado por $G = I_{20}(i, j) - I_1(i, j)$. Essa medida informa o quanto uma dada região se aqueceu ou esfriou durante o tempo de extração das características. Durante os teste realizados notamos regiões que sofrem algum tipo de anomalia tendem a ganhar mais temperatura durante o tempo de extração das imagens. Em imagens saudáveis quando ocorre esse tipo de comportamento, geralmente a um tipo de espalhamento, de forma que ele aparece nas duas mamas. Na Figura 25a vemos uma TID de paciente saudável. Notamos um aspecto simétrico entre as regiões. Já a Figura 25b possui uma região de alto ganho de temperatura em relação as demais da mama, coincidindo com a região em que o tumor existe.
- O ganho médio de temperatura entres os tempos dado pela Equação 4.1. Essa característica se assemelha ao ganho total de temperatura, onde regiões com algum tipo de anomalia tendem ter uma média maior que as demais regiões e não apresentam uma similaridade na mesma região da outra mama. A Figura 26 apresenta o resultado da extração dessa característica em TID de paciente saudável e em uma TID de paciente doente.
- O desvio padrão do ganho de temperatura entres os tempos dada pela Equação 4.2. Essa característica apresenta um grande fator de discriminância entres regiões saudáveis e com anomalias. Regiões saudáveis tendem a ganhar temperatura de forma uniforme durante a aquisição dos termogramas, ao contrário de regiões anômalas que variam bastante no ganho de temperatura. Dessa forma regiões saudáveis apresentam um valor para S mais baixo em relação à regiões que possuem algum tipo

de anomalia. A Figura 27 apresenta o desvio padrão do ganho de temperatura em uma TID de paciente saudável e em uma TID de paciente doente.

$$M = \frac{1}{19} \cdot \sum_{t=2}^{20} I_t(i, j) - I_{t-1}(i, j) \quad (4.1)$$

$$S = \sqrt{\frac{1}{19} \cdot \sum_{t=2}^{20} ((I_t(i, j) - I_{t-1}(i, j)) - M)^2} \quad (4.2)$$

Essas características quando analisadas em conjunto oferecem um grande discriminador entre as pacientes. É possível perceber a similaridade entre as mamas direita e esquerda nas Figuras 24a, 25a e 26a, e uma homogeneidade na Figura 27a. Essas imagens representam uma paciente saudável. Já nas Figuras 24b, 25b e 26b a similaridade entre as mamas é quebrada por regiões de pico de valores que são coincidentes entre elas, e na Figura 27b temos regiões com uma maior desvio padrão em relação as demais regiões da mama, coincidindo com as regiões de maior pico nas imagens das outras características.

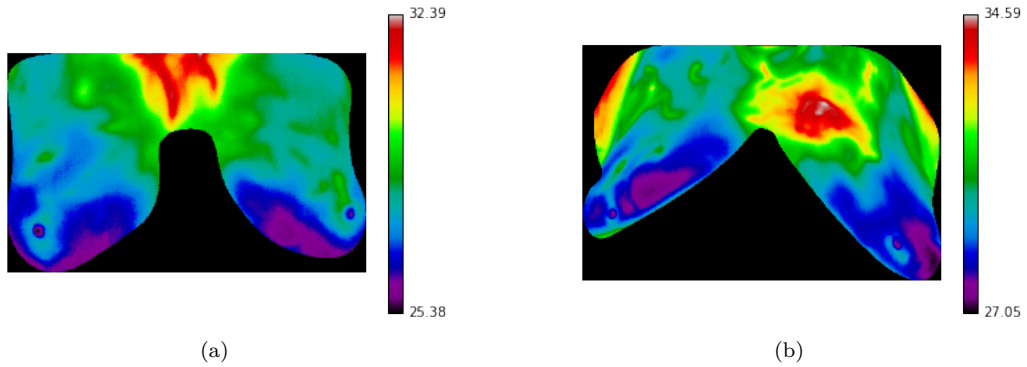


Figura 24 – Temperatura Inicial. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante. Note a assimetria existente em (b).

Fonte: Elaborada pelo autor




Figura 25 – Ganho de temperatura total. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com carcinoma ductal infiltrante. A região mais avermelhada em (b) coincide com a região em que o tumor aparece.

Fonte: Elaborada pelo autor




Figura 26 – Ganho de temperatura média entre os tempos da TID. Em (a) vemos um exame de paciente saudável, enquanto em (b) temos uma paciente com lesão na mama.

Fonte: Elaborada pelo autor




Figura 27 – Desvio padrão do ganho de temperatura em uma TID. Em (a) temos um termograma de paciente saudável, enquanto em (b) temos uma paciente com lesão.

Fonte: Elaborada pelo autor

4.5 Extração de Características 2

A partir das imagens geradas na Seção 4.4, são extraídas um conjunto de características baseadas em GLCM, definidas pelas Equações 3.25,3.26,3.27,3.28,3.29 e 3.30.

Antes de gerarmos as GLCM é necessário converter a escala de valores para níveis de cinza. Essa conversão é obtida através de

$$X' = a - \frac{(X - X_{min})(b - a)}{X_{max} - X_{min}}, \quad (4.3)$$

onde X é o conjunto de valores, X_{min} o menor valor do conjunto, X_{max} o maior valor, b o valor máximo desejado e a o valor mínimo desejado. No caso das imagens extraídas na Seção 4.4 temos $a = 0$ e $b = 255$, dessa forma serão convertidas em níveis de cinza.

A partir das imagens convertidas para valores de níveis de cinza podemos extrair as GLCM. No total são extraídas 4 matrizes, com distâncias $(\Delta x = 1, \Delta y = 0)$, $(\Delta x = 1, \Delta y = 1)$, $(\Delta x = 0, \Delta y = 1)$ e $(\Delta x = -1, \Delta y = 1)$. A partir daí serão geradas as 6 características citadas acima para cada matriz, formando um total de 96 características que serão utilizadas na etapa de classificação da metodologia.

4.6 Redução de Características

Essa etapa consiste em reduzir o conjunto de 96 características previamente extraídas para um conjunto menor e mais conciso de características. Foram utilizados os 3 métodos descritos na Seção 3.4. Dessa forma temos distintos conjuntos de dados que serão utilizados na etapa de classificação, sendo eles:

- K-best com $K = 40$.
- K-best com $K = 20$.
- K-best com $K = 10$.
- PCA com $C = 20$.
- PCA com $C = 10$.
- LDA com $C = 1$.

4.7 Classificação

Essa etapa consiste em classificar um determinado exame TID em saudável ou doente. Utilizando as características extraídas da Seção 4.5 e posteriormente reduzidas como entrada para uma SVM.

Durante essa etapa o conjunto de características originais são subdividas em 2 conjuntos distintos que chamamos de base de treino e teste, que não possuem indivíduos em comum entre eles. Antes da etapa de treinamento de uma SVM, selecionamos as melhores características através de um dos métodos descritos na Seção 4.6. Essa seleção é feita na base de treino e depois aplicada na base de testes, dessa forma a base de teste não tem influência na seleção.

A etapa de treinamento entra em ação, onde a base de treino juntamente com seus valores de classe é utilizada para encontrar os melhores vetores de suporte para a SVM. Após o termino do treinamento, a validação do modelo é executada, onde utilizamos a base de teste sem os valores de classe como entrada no modelo SVM, que irá classificar os indivíduos existentes na base. Os resultados são comparados com os valores de classe conhecidos para validação do modelo. São extraídos os valores de acurácia (Equação 4.4) que mede a taxa de acerto geral, a sensibilidade (Equação 4.5) que mede a taxa de acerto para os casos que possuem anomalia e a especificidade (Equação 4.6) que mede a taxa de acerto de casos saudáveis.

$$Acurácia = \frac{TP + TN}{TP + FP + TN + FN} \quad (4.4)$$

$$Sensibilidade = \frac{TP}{TP + FN} \quad (4.5)$$

$$Especificidade = \frac{TN}{TN + FP} \quad (4.6)$$

onde TP , TN , FP e FN são as quantidades de verdadeiro positivo, verdadeiro negativo, falso positivo e falso negativo, respectivamente.

5 Resultados Parciais

Nesse capítulo são apresentados os resultados parciais da aplicação da metodologia para a classificação de termografias dinâmicas em saudável e doente. Os testes são aplicados 100 vezes consecutivas e a média dos resultados é analisada. Em cada teste, a base é inicialmente dividida em 80% dos casos para o treinamento do SVM e 20% para validação do modelo. Os indivíduos são selecionados aleatoriamente de forma que a proporção entre as classes seja mantida. Como a base utilizada apresenta balanceamento de 1:1 entre as classes, não ocorre o desbalanceamento na etapa de treinamento e validação. Após a divisão das bases, a redução de dimensionalidade é utilizada, onde a base de treino é utilizada como referência para a análise de quais características são as mais eficientes. As técnicas de redução utilizadas são as descritas na Seção 4.6. Então a base de treino é utilizada para gerar o modelo SVM, que posteriormente será utilizado na classificação dos indivíduos. A Tabela 1 apresenta os resultados parciais da metodologia.

Método	Acurácia	Sensibilidade	Especificidade
Sem redução	42,4%	23,7%	68,9%
K-best, K=40	48,1%	28,1%	68,1%
K-best, K=20	49,8%	29,1%	70,5%
PCA, K=30	48,2%	44,1%	52,2%
PCA, K=20	47,5%	44,7%	54,4%
LDA, K=1	78,3%	79,9%	76,7%
PCA+LDA, k1= 40, k2=1	82,5%	84,1%	81,0%

Tabela 1 – Média final da execução dos testes 100 vezes para cada método de seleção de características.

Analisando a tabela, vemos que a estratégia sem reduzir as características não apresenta bom resultado, ficando abaixo dos 50% de acurácia. As técnicas *K-best* e PCA também não produziram resultados satisfatórios. A técnica de redução que obteve um bom resultado foi a LDA, que sozinho demonstrou ser a melhor para a redução das características. No entanto, a combinação da aplicação do PCA seguida da aplicação do LDA foi a que demonstrou melhores resultados nos testes realizados até o momento, onde a acurácia, sensibilidade e especificidade ficaram acima dos 80%.

Um fator que contribui bastante para os resultados abaixo do esperado é a quantidade de exames disponíveis. A base utilizada é relativamente pequena em comparação com bases utilizadas por metodologias baseadas em mamografia, que chegam a possuir mais de 3000 mil exames disponíveis para os pesquisadores. Apesar disso, é possível dizer que os resultados demonstrados são promissores e com a utilização de outras características que possam discriminar as classes é possível que melhores resultados sejam obtidos.

6 Cronograma do Plano de Trabalho

A plano de trabalho na elaboração da metodologia pode ser subdividido em:

1. Pesquisa Bibliográfica
2. Coleta de Dados
3. Elaboração do Projeto de Monografia
4. Revisão Gramatical e Ortográfica
5. Defesa de Monografia

A Tabela2 apresenta o cronograma de execução das atividades.

Etapas	09/2015	10/2015	11/2015	12/2015	01/2016	02/2016	03/2016	04/2016
1	X	X	X					
2			X	X				
3				X	X	X		
4						X	X	
5								X

Tabela 2 – Cronograma do plano de trabalho.

7 Conclusão

A metodologia apresenta uma forma de auxiliar médicos especialistas na detecção do câncer de mama. O objetivo não é indicar o local suspeito, apenas dizer se um determinado paciente apresenta ou não algum tipo de anomalia na região das mamas.

A termografia é um exame que não deve ser utilizado isoladamente para a detecção desse tipo de câncer, mas em conjunto com outros tipos de exame, como a mamografia. A vantagem desse tipo de imagem é que o equipamento utilizado para extração das imagens é fácil de carregar, permitindo a locomoção para diferentes lugares. Apesar disso, é necessário um ambiente controlado na etapa de extração das imagens.

O resultados apresentados pela metodologia demonstram ser promissores, com 82,5% de acurácia, 84,1 % de sensibilidade e 81,0% de especificidade.

7.1 Trabalhos Futuros

O maior impasse na metodologia é pequena base de imagens previamente diagnosticadas disponível. Foram utilizadas apenas 70 imagens na metodologia, longe da quantidade ideal para algoritmos de aprendizado de máquina. Com a obtenção de novas imagens é possível conseguir melhores resultados.

Novos métricas também podem ser estudadas, com o objetivo de incluí-las na metodologia apresentada, deixando-a mais robusta e mais precisa.

Referências

- INCA. *Mama*. 2016. <<http://www2.inca.gov.br/wps/wcm/connect/tiposdecancer/site/home/mama>>. Acessado em: 05/03/2016.
- BORCHARTT, T. B. et al. Breast thermography from an image processing viewpoint: A survey. *Signal Processing*, Elsevier, v. 93, n. 10, p. 2785–2803, 2013.
- SILVA, L. et al. A new database for breast research with infrared image. *Journal of Medical Imaging and Health Informatics*, American Scientific Publishers, v. 4, n. 1, p. 92–100, 2014.
- SILVA, L. F. D. *Uma Análise Híbrida para Detecção de Anomalias da Mama usando Séries Temporais de Temperatura*. Tese (Doutorado) — Universidade Federal Fluminense, 2015.
- ANBAR, M. Computerized thermography. *International journal of technology assessment in health care*, Cambridge Univ Press, v. 3, n. 04, p. 613–621, 1987.
- AMALU, W. C. Nondestructive testing of the human breast: the validity of dynamic stress testing in medical infrared breast imaging. In: IEEE. *Engineering in Medicine and Biology Society, 2004. IEMBS'04. 26th Annual International Conference of the IEEE*. [S.l.], 2004. v. 1, p. 1174–1177.
- IBANEZ, L. et al. The itk software guide. 2003.
- BROWN, L. G. A survey of image registration techniques. *ACM computing surveys (CSUR)*, ACM, v. 24, n. 4, p. 325–376, 1992.
- CRUM, W. R.; HARTKENS, T.; HILL, D. Non-rigid image registration: theory and practice. *The British Journal of Radiology*, British Institute of Radiology, 2014.
- PARRAGA, A. Atlas anatômico da região da cabeça e do pescoço: em direção à radioterapia adaptativa. 2008.
- YIN, Y.; HOFFMAN, E. A.; LIN, C.-L. Mass preserving nonrigid registration of ct lung images using cubic b-spline. *Medical physics*, American Association of Physicists in Medicine, v. 36, n. 9, p. 4213–4222, 2009.
- SCHWARZ, L. A. *Non-rigid registration using free-form deformations*. Tese (Doutorado) — Ph. D. thesis, Technische Universität München, Germany, 2007.
- WHITLEY, D. A genetic algorithm tutorial. *Statistics and computing*, Springer, v. 4, n. 2, p. 65–85, 1994.
- BURGES, C. et al. Learning to rank using gradient descent. In: ACM. *Proceedings of the 22nd international conference on Machine learning*. [S.l.], 2005. p. 89–96.
- SHEPPARD, D.; TERRELL, R.; HENKELMAN, G. Optimization methods for finding minimum energy paths. *The Journal of chemical physics*, AIP Publishing, v. 128, n. 13, p. 134106, 2008.
- HARALICK, R. M.; SHANMUGAM, K.; DINSTEN, I. H. Textural features for image classification. *Systems, Man and Cybernetics, IEEE Transactions on*, Ieee, n. 6, p. 610–621, 1973.
- SEBASTIAN, V. et al. Gray level co-occurrence matrices: Generalisation and some new features. *arXiv preprint arXiv:1205.4831*, 2012.
- ALBREGTSEN, F. et al. Statistical texture measures computed from gray level cooccurrence matrices. *Image processing laboratory, department of informatics, university of oslo*, p. 1–14, 2008.
- HALL-BEYER, M. *The GLCM Tutorial Home Page*. <<http://www.fp.ucalgary.ca/mhallbey/tutorial.htm>>. Acessado em : 18/02/2016.
- HARALICK, R. M. Statistical and structural approaches to texture. *Proceedings of the IEEE*, IEEE, v. 67, n. 5, p. 786–804, 1979.

- CONNERS, R. W.; TRIVEDI, M. M.; HARLOW, C. A. Segmentation of a high-resolution urban scene using texture operators. *Computer Vision, Graphics, and Image Processing*, Elsevier, v. 25, n. 3, p. 273–310, 1984.
- FODOR, I. K. *A survey of dimension reduction techniques*. [S.l.]: Technical Report UCRL-ID-148494, Lawrence Livermore National Laboratory, 2002.
- LEARN scikit. *Feature Selection*. Disponível em: <http://scikit-learn.org/stable/modules/feature_selection.html>. Acesso em: 20/02/2016.
- JACKSON, J. E. *A user's guide to principal components*. [S.l.]: John Wiley & Sons, 2005. v. 587.
- RASCHKA, S. *Linear Discriminant Analysis bit a bit*. Disponível em: <http://sebastianraschka.com/Articles/2014_python_lda.html>. Acesso em: 22/02/2016.
- FISHER, R. A. The use of multiple measurements in taxonomic problems. *Annals of eugenics*, Wiley Online Library, v. 7, n. 2, p. 179–188, 1936.
- RAO, C. R. The utilization of multiple measurements in problems of biological classification. *Journal of the Royal Statistical Society. Series B (Methodological)*, JSTOR, v. 10, n. 2, p. 159–203, 1948.
- CORTES, C.; VAPNIK, V. Support vector machine. *Machine learning*, v. 20, n. 3, p. 273–297, 1995.
- LEARN scikit. *Support Vector Machines*. Disponível em: <<http://scikit-learn.org/stable/modules/svm.html>>. Acesso em: 23/02/2016.
- SILVA, G. L. F. da. Monografia, *Análise de Nódulos Pulmonares Usando Índices de Diversidade para estabelecer possíveis diferenças entre padrões malignos e benignos*. 2015. Monografia (Bacharel em Ciência da Computação), UFMA (Universidade Federal do Maranhão).
- CHAVES, A. d. C. F. *Extração de Regras Fuzzy para Máquinas de Vetores Suporte (SVM) para Classificação em Múltiplas Classes*. Tese (Doutorado) — PUC-Rio, 2006.
- HAYKIN, S. S. *Redes neurais*. [S.l.]: Bookman, 2001.
- MARQUES, R. Segmentação automática das mamas em imagens térmicas. *UFF, M. Sc. Thesis*, 2012.
- ABRÀMOFF, M. D.; MAGALHÃES, P. J.; RAM, S. J. Image processing with imagej. *Biophotonics international*, Laurin Publishing, v. 11, n. 7, p. 36–42, 2004.
- RASBAND, W.; IMAGEJ, U. et al. *Bethesda, Md, USA*. [S.l.]: ImageJ, 1997.